

국내외 AI 반도체 기업 통합 RAG 조사자료

스타트업 탐색 · 기술 요약 · 시장성 평가

50개 기업·사업 사례를 조사하고 기술·시장 주제 30개를 함께 정리했습니다. 국내외 AI 계산 칩을 중심으로, 비교에 필요한 상장·인수 기업과 연결·메모리 인접 분야를 명시적으로 구분합니다.

조사 범위	내용
기업	국내 8개 / 해외 42개. 모든 항목이 독립 비상장 스타트업인 것은 아닙니다.
기업별 구성	사업·제품·기술 근거 1페이지 + 시장성·한계·검증 질문 1페이지
공통 조사	기술 15개 주제 + 시장 15개 주제
출처	공식 제품·기업 발표·논문·기관 자료 90개 URL
기준일	2026년 9월 29일. 과거 이벤트는 해당 날짜를 유지.
분량	표지·목차·본문·출처를 포함하여 정확히 150페이지

사용 목적

질의 조건에 맞는 후보와 근거를 반환하기 위한 사전 조사 문서입니다. 기업별 장단점은 적용 조건이 있는 분석으로 제시합니다. 비공개 재무·고객 계약·독립 실측이 없는 항목은 확인되지 않은 상태로 남깁니다.

공개 자료의 필요한 사실을 요약했습니다. 원문 전체·유료 보고서·접근 제한 논문은 복제하지 않았습니다.

범위·출처·해석 기준

포함 기준

AI 연산용 칩·반도체 IP·관련 시스템의 기술 설명이 공개된 기업을 우선 선정했습니다. 광연결·CXL·네트워크·HPC CPU는 인접 분야로 넣었습니다. 공식 원문을 충분히 확인하지 못한 기업을 숫자를 채우기 위해 추가하지 않았습니다.

표시	의미	답변에서의 사용
공개 사실	회사가 제품·사업을 그렇게 설명함	회사 공개라고 명시
논문	특정 연구의 방법·실험	해당 범위에서만 해석
기관 자료	통계·전망·분류	실적과 전망 구분
분석	사실을 바탕으로 작성한 적용·위험 가설	확정 장단점으로 전환 금지
미확인	이번 조사에서 입증하지 못함	추정 수치로 채우지 않음

최신성의 한계

제품 페이지의 조회일은 출시일이 아닙니다. 오래된 투자 이벤트는 현재 최종 라운드로 단정하지 않습니다. 회사 상태는 확인한 발표 범위로 표시했고, 별도 확인이 필요한 항목에는 그 사실을 적었습니다. 법인별 국적·투자 가능성은 별도 실사가 필요합니다.

비교 범위

국내 8개에는 Panmnesia와 같은 인접 기업이 포함됩니다. 상장·인수 비교 기업은 스타트업 후보와 자동으로 합치지 않습니다. 기업 수와 페이지 수는 조사 범위를 나타내며 전 세계 기업의 완전한 목록이나 투자 순위를 의미하지 않습니다.

목차와 에이전트별 페이지

페이지	내용	에이전트
1-6	범위·목차·50개 기업 색인	탐색
7-22	국내 8개 기업·사업 사례	공통
23-106	해외 42개 기업·사업 사례	공통
107-121	기술 구조와 성능 비교 15개 주제	기술 요약
122-136	수요·시장·상용화·사업성 15개 주제	시장성 평가
137-140	RAG 저장·검색·출처·검수 설계	공통
141-150	출처 목록 90개 URL	근거 추적

기업 두 페이지의 역할

첫 페이지는 어떤 기업이며 무엇을 만드는지와 기술 근거를 담습니다. 둘째 페이지는 누구에게 팔 수 있는지, 어떤 위험이 있는지, 다음 검증에 필요한 질문을 담습니다. 둘째 페이지의 분석은 해당 회사가 보증하는 사실이 아닙니다.

질의별 읽는 경로

“국내 저전력 엣지 칩”은 4쪽 색인에서 시작합니다. “데이터센터 추론 가속기”는 5-6쪽 색인과 108쪽 prefill/decode를 함께 봅니다. “투자 가능한 독립 스타트업”은 회사 상태를 먼저 확인하고 132쪽 상장·인수 사례를 참고합니다.

인용 방법

답변에는 기업명, 문서 페이지, 출처 ID와 조회 시점을 연결합니다. 예: “DEEPIX의 제품 사양은 회사 공개 자료에 근거하며 실제 장치 전력은 별도 확인이 필요합니다. [15쪽, S010]”. PDF의 북마크로 기업과 주제에 바로 이동할 수 있습니다.

국내 기업 색인

기업	제품·기술	범주	쪽
FuriosaAI	RNGD	데이터센터 AI 계산	7-8
Rebellions	REBEL100 / RebelRack	데이터센터 AI 계산	9-10
HyperAccel	LPU IP	AI 반도체 IP	11-12
Mobilint	ARIES	엣지 AI·영상 계산	13-14
DEEPX	DX-M1	엣지 AI·영상 계산	15-16
AiM Future	NeuroMosAIC / Studio	AI 반도체 IP	17-18
BOS Semiconductors	Eagle-N / Eagle-A	자동차·Physical AI	19-20
Panmnesia	PanSwitch / PanFabric	연결·메모리 인프라	21-22

검색 시 주의

연산 칩과 IP, 메모리 연결 제품을 같은 순위로 비교하지 않습니다. Rebellions의 pre-IPO 발표와 다른 기업의 과거 Series A·B·C는 현재 상태를 완전히 설명하는 동일 기준의 값이 아닙니다.

국내 후보 확장 방향

공개 근거가 있는 가전·차량·메모리 연결 영역까지 넓혔습니다. 제품 이름·영문 법인명·한글 별칭을 같은 company_id에 연결하면 동일 기업이 다른 후보로 중복 반환되는 문제를 줄일 수 있습니다.

해외 기업 색인 1 / 2

기업	제품·기술	쪽
d-Matrix	Corsair	23-24
Tenstorrent	Blackhole / Tensix	25-26
Etched	추론 클러스터	27-28
Hailo	Hailo-8 / Hailo-10H / Hailo-15	29-30
Kneron	NPU / KNEO	31-32
Axelera AI	Metis / Europa / Voyager	33-34
SiMa.ai	Modalix MLSoC / Palette	35-36
MemryX	MX3 / Cascade / MX4	37-38
Syntiant	Neural Decision Processor	39-40
Ambient Scientific	GPX10 / DigAn	41-42
AONDevices	AON11xx / AONx360	43-44
EdgeCortex	SAKURA / MERA / RAIDEN	45-46
NEUCHIPS	Raptor N3000 / Viper	47-48
Mythic	APU / analog compute-in-memory	49-50
Innatera	Pulsar / spiking neural processor	51-52
SynSense	뉴로모픽 sense + compute	53-54
SpiNNcloud	동적 희소성 추론 시스템	55-56
Synthara	ComputeRAM	57-58
SEMRON	3D CapRAM	59-60
Fractile	메모리·연산 통합 추론 프로세서	61-62
MatX	MatX One	63-64

지역명보다 현재 법인 상태·판매 제품·실제 워크로드를 우선해 후보를 좁힙니다. 상장·인수·인접 분야 여부는 각 기업의 상태 필드를 확인하세요.

해외 기업 색인 2 / 2

기업	제품·기술	쪽
Positron	Atlas / Asimov	65-66
Tensordyne	Napier / Recogni 계보	67-68
Esperanto Technologies	ET-SoC-1	69-70
Openchip	RISC-V 가속기·통합 스택	71-72
SiPearl	Rhea1	73-74
Enfabrica	ACF-S / EMFASYS	75-76
Cerebras	Wafer-Scale Engine / CS-4	77-78
SambaNova	RDU / SambaRack SN50	79-80
Groq	LPU 계보 / 추론 클라우드	81-82
Graphcore	AI compute / IPU 계보	83-84
Blaize	GSP / Pathfinder / Xplorer	85-86
BrainChip	Akida / Akida GenAI	87-88
Kinara	Ara-1 / Ara240	89-90
Lightmatter	Passage / Guide	91-92
Lightelligence	PACE 2 / Photowave	93-94
Celestial AI	Photonic Fabric	95-96
Lumai	3D optical compute	97-98
Q.ANT	Native Processing Server / NPU Gen 2	99-100
Biren Technology	GPU / chiplet	101-102
Moore Threads	MTT S5000 / MUSA	103-104
REEXEN	ADA300 / SRAM CIM	105-106

지역명보다 현재 법인 상태·판매 제품·실제 워크로드를 우선해 후보를 좁힙니다. 상장·인수·인접 분야 여부는 각 기업의 상태 필드를 확인하세요.

FuriosaAI

C01 | 국내 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

RNGD를 중심으로 AI 추론 가속기를 개발합니다. 2025년 7월 회사는 1억 2,500만 달러 Series C bridge와 LG AI Research의 EXAONE용 도입을 발표했습니다. 고객 채택은 회사 발표이며 매출 규모·계약 범위는 이 자료에서 확인하지 않았습니다. [S001, S002]

핵심 기술 | 공개 자료

현재 제품 페이지의 RNGD PCIe 카드 사양은 FP8 peak 512 TFLOPS, HBM3 48GB, 메모리 대역폭 1.5TB/s, SRAM 256MB, TDP 180W입니다. [S001] TCP 논문은 tensor contraction에 맞춘 데이터 흐름과 컴파일러의 공동 설계를 설명합니다. 2024년 논문상의 칩 전력과 현행 카드 TDP는 시점·측정 경계가 달라 동일한 값으로 합치지 않습니다. [S003]

필드	조사 기록
제품·기술	RNGD
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	기업 AI 인프라·클라우드 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

국내 데이터센터 LLM 추론 칩, HBM 48GB 추론 가속기, tensor contraction processor

근거: S001 · S002 · S003. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

FuriosaAI | 시장성과 확인 과제

C01 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

모델 연산을 하드웨어에 효율적으로 배치하려는 구조가 차별화 가설입니다. 기업 내 LLM 서비스, 전력 제약이 있는 추론 인프라 질의의 후보가 됩니다. 메모리와 카드 단위 전력은 후보를 좁히는 조건이지 서비스 효율의 확정 증거는 아닙니다.

한계·도입 위험 | 분석·미확인

실제 모델별 지연·처리량, 멀티카드 확장, 컴파일러 미지원 연산자, 소프트웨어 이전 기간, 구매·유지보수 비용을 확인해야 합니다. 공개 채택이 반복 구매로 이어지는지는 별도 검증 대상입니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. 동일 LLM과 정확도 조건에서 카드 수·전력·지연을 측정하고 기존 서버 대비 이전 비용까지 산정합니다. GPU와 비교할 때는 카드 peak 수치가 아닌 서비스 기준 총비용을 사용합니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	Rebellions, d-Matrix, Tenstorrent
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

FuriosaAI은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S001 · S002 · S003 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Rebellions

C02 | 국내 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

REBEL100과 랙·팟 단위 제품을 제시합니다. 2026년 3월 30일 회사는 4억 달러 pre-IPO 투자 및 RebelRack·RebelPod 출시를 발표했습니다. 초기 단계 스타트업만 찾는 질의에는 투자 단계 조건을 별도로 적용해야 합니다. [S004, S005]

핵심 기술 | 공개 자료

REBEL100은 4개 동종 칩렛과 UCle-Advanced 연결, HBM3E 144GB·4.8TB/s를 제시합니다. 공개 사양은 FP16 dense 1,024 TFLOPS, FP8 2,048 TFLOPS, 최대 600W입니다. [S004] 제품 페이지는 PyTorch 2.x, vLLM, Triton 지원을 소개합니다. 프레임워크 지원은 모든 모델과 연산자가 수정 없이 실행된다는 뜻은 아닙니다. [S004]

필드	조사 기록
제품·기술	REBEL100 / RebelRack
기업 상태	2026-03 pre-IPO 발표 / 현재 단계 별도 확인
주요 고객 가설	기업 AI 인프라·클라우드 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

국내 HBM3E AI 칩, 랙 단위 LLM 추론, UCle 칩렛 스타트업

근거: S004 · S005. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Rebellions | 시장성과 확인 과제

C02 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

칩부터 랙까지 제공하는 접근은 큰 모델의 수용성과 통합 도입을 중요하게 보는 고객에게 적합할 가능성이 있습니다. 기업·클라우드의 추론 클러스터 구축 질의에 연결할 수 있습니다.

한계·도입 위험 | 분석·미확인

냉각·전력 공급, 시스템 단위 통신 병목, 실제 모델별 지원 범위, 랙 설치와 운영 비용을 검증해야 합니다. 제품 페이지의 비교 성능 주장을 조건이 같은 독립 실험 결과로 간주하지 않습니다.

기업별 확인 질문

1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
2. 구매 가능한 랙 구성과 납기를 확인하고 고객 모델의 지연 제한을 만족하는 처리량을 측정합니다. 칩 사양, 서버 구성, 랙 총전력은 각각 다른 필드로 저장합니다.
3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, d-Matrix, Tenstorrent
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Rebellions은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S004 · S005 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

HyperAccel

C03 | 국내 | AI 반도체 IP

기업·사업 근거 | 공개 자료

LLM Processing Unit을 뜻하는 LPU 기술을 소개합니다. 회사의 2025년 발표 자료는 550억 원 Series A 유치를 설명합니다. 페이지 날짜와 본문의 발표일 표현이 일치하는지 명확하지 않아 이벤트는 연도 수준으로 기록합니다. [S006, S007]

핵심 기술 | 공개 자료

LPU IP는 메모리·연산 구성을 조절하는 모듈형 설계와 PCIe·UCle 통합을 제시합니다. 공개 구성 예시는 latency 지향 코어 8 TFLOPS FP16·3.55W, high-performance 코어 12 TFLOPS·4.72W입니다. 이는 코어 단위 예시입니다. [S006] IP의 코어 수치와 완성 카드·서버 수치를 직접 비교하면 안 됩니다. LPU라는 명칭은 업체별로 의미가 다를 수 있으므로 company_id와 함께 색인합니다. [S006; 분석]

필드	조사 기록
제품·기술	LPU IP
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	SoC 설계사·추론 서버 개발사
측정할 조건	목표 공정·면적·모델·검증 조건
평가 지표	PPA·통합 기간·지원 연산
시스템 경계	IP·메모리·SoC·툴체인

탐색 태그

LLM 전용 반도체 IP, 국내 LPU 설계, 커스텀 추론 SoC

근거: S006 · S007. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

HyperAccel | 시장성과 확인 과제

C03 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

LLM에 맞춘 IP를 고객 SoC에 통합하려는 수요와 추론 서버 수요를 나누어 평가할 수 있습니다. IP 사업은 설계 채택과 라이선스·양산 로열티의 시점이 다르므로 매출 발생 구조 확인이 중요합니다.

한계·도입 위험 | 분석·미확인

완성 실리콘의 측정 조건, 양산 일정과 수율, 지원 모델, IP 라이선스 형태, 고객 설계 채택 여부를 확인해야 합니다. 투자 발표의 미래 생산 계획을 이미 달성한 실적으로 저장하지 않습니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. IP 구매자인지 서버 구매자인지 먼저 구분합니다. 전자는 공정·검증·통합 일정, 후자는 실제 처리량·서비스 비용·운영 지원을 중심으로 평가합니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	AiM Future, Synthara
고객 PoC의 고정 조건	목표 공정·면적·모델·검증 조건
결과 판정	PPA·통합 기간·지원 연산을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

HyperAccel은(는) AI 반도체 IP 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S006 · S007 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Mobilint

C04 | 국내 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

ARIES를 통해 영상·로봇·산업 현장의 AI 추론을 겨냥합니다. 회사 연혁에는 2019년 설립, 2024년 Series B가 기재되어 있습니다. 이 이벤트가 현재 최종 투자 단계인지는 확인하지 않았습니다. [S008, S009]

핵심 기술 | 공개 자료

ARIES 페이지는 80 TOPS, LPDDR4X 16GB 또는 32GB 옵션, 66.7GB/s, PCIe Gen4 x8을 제시합니다. 본문은 20W의 성능 표현을 쓰고 사양표는 TDP 25W를 표기합니다. 두 전력 값을 하나의 확정 측정치로 합치지 않습니다. [S008] 전력 차이는 동작 조건이나 측정 경계에 따른 것일 수 있으나 공개 페이지만으로 원인을 확정하지 않았습니다. “80 TOPS / 20W / TDP 25W”를 각각 원문 문맥과 함께 보존해야 합니다. [S008; 분석]

필드	조사 기록
제품·기술	ARIES
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	산업 장비·엣지 시스템 OEM
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

국내 엣지 NPU, 공장 영상 분석 가속기, PCIe 영상 AI 칩

근거: S008 · S009. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Mobilint | 시장성과 확인 과제

C04 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

여러 카메라의 현장 추론, 공장·로봇의 지연 제약, 외부 전송을 줄이려는 수요가 후보 시장입니다. 이점은 실제 영상 파이프라인의 처리량과 운영 환경에서 확인해야 합니다.

한계·도입 위험 | 분석·미확인

모델별 정확도 유지, CPU 전후처리 부하, 카메라 입력 병목, 장시간 온도·소비전력, SDK 호환성을 확인해야 합니다. 여러 모델 지원이라는 표현을 임의의 모델 호환성으로 확대하지 않습니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. 실제 카메라 수·해상도·프레임률·모델을 고정해 지연과 누락 프레임을 측정합니다. 카드 전력 외에 호스트와 냉각 전력을 포함한 장비 비용을 평가합니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	DEEPX, Hailo, Kneron
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Mobilint은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이 나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S008 · S009 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

DEEPX

C05 | 국내 | 엣지 AI · 영상 계산

기업 · 사업 근거 | 공개 자료

DX-M1은 현장 · 장치 내부의 AI 추론을 위한 제품입니다. DEEPX가 배포한 2024년 5월 보도자료는 8,050만 달러 Series C 유치를 발표합니다. PR Newswire 게재는 배포 경로이며 독립적 검증을 뜻하지 않습니다. [S010, S011]

핵심 기술 | 공개 자료

DX-M1의 사양표는 INT8 25 TOPS, 1-5W, PCIe Gen3 x4를 제시합니다. 칩 설명은 LPDDR4x 또는 LPDDR5와 최대 8GB, M.2 모듈 설명은 4GB LPDDR5를 구분합니다. [S010] 같은 페이지의 “200 GPU-class TOPS”는 등가 성능 홍보 표현입니다. 원시 연산량 필드는 사양표의 INT8 25 TOPS를 사용하고, 홍보 표현을 동일한 단위의 실측값으로 대체하지 않습니다. [S010]

필드	조사 기록
제품 · 기술	DX-M1
기업 상태	공개 사업 확인 / 최신 법인 · 자본 상태 별도 확인
주요 고객 가설	산업 장비 · 엣지 시스템 OEM
측정할 조건	센서 수 · 해상도 · 모델 · 온도
평가 지표	정확도 · 프레임 지연 · 지속 성능
시스템 경계	가속기 · 호스트 · 센서 · 방열

탐색 태그

5W 이하 엣지 AI 칩, M.2 NPU 모듈, 온디바이스 영상 추론

근거: S010 · S011. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용 · 시장 분석은 별도 가설입니다.

DEEPX | 시장성과 확인 과제

C05 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

낮은 전력 예산의 스마트 카메라·로봇·산업 장비 질의에 적합한 후보입니다. 클라우드 연결 지연과 데이터 전송량을 줄이려는 요구가 채택 이유가 될 수 있으나, 판매 규모를 직접 보여 주지는 않습니다.

한계·도입 위험 | 분석·미확인

양자화 후 정확도, 메모리 한도, 모델 변환 과정, 시스템 전력, 방열 조건, 고객 설계 채택부터 양산까지의 일정을 확인해야 합니다. 이번 조사에서 2024년 이후의 최종 투자 단계를 확정하지 않았습니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. 목표 모델을 메모리에 적재한 뒤 실제 데이터셋의 정확도와 지연을 측정합니다. 칩과 모듈의 메모리 사양을 구분하고 고객 장치의 열 설계 안에서 지속 성능을 확인합니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, Hailo, Kneron
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

DEEPX은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S010 · S011 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

AiM Future

C06 | 국내 | AI 반도체 IP

기업·사업 근거 | 공개 자료

NPU 가속기 IP, 엣지 AI SoC와 시스템 통합 서비스를 소개합니다. IoT·가전·자동차를 목표 응용으로 제시하며, 기술 라이선스와 고객 시스템 개발을 함께 다루는 기업입니다. [S025]

핵심 기술 | 공개 자료

NeuroMosAIC Studio는 모델 변환·매핑·컴파일·시뮬레이션·프로파일링 흐름을 제공합니다. IP 블록 자체와 이를 통합한 최종 칩의 성능·전력은 서로 다른 수준에서 평가해야 합니다. [S025]

필드	조사 기록
제품·기술	NeuroMosAIC / Studio
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	가전·IoT SoC 설계사와 ODM
측정할 조건	목표 공정·면적·모델·검증 조건
평가 지표	PPA·통합 기간·지원 연산
시스템 경계	IP·메모리·SoC·툴체인

탐색 태그

AiM Future, NeuroMosAIC / Studio, 가전·IoT SoC 설계사와 ODM

근거: S025. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

AiM Future | 시장성과 확인 과제

C06 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

가전의 음성·영상 인식을 기존 SoC에 통합하려는 고객을 탐색할 수 있습니다. 고객이 외부 NPU 칩 대신 자체 칩 내 IP를 선택한다면 부품 수와 제품 설계의 제약이 달라집니다. 기술 지원이 반복 가능한 라이선스 매출로 이어지는지가 사업성의 핵심입니다.

한계·도입 위험 | 분석·미확인

고객별 맞춤 개발 비중이 높으면 매출이 늘어도 엔지니어 투입이 함께 증가할 수 있습니다. 설계 채택, 테이프아웃, 양산 로열티를 각각 확인해야 합니다.

기업별 확인 질문

- 1. 목표 공정에서 합성 면적·주파수·전력을 고객 제약으로 검증할 수 있는가?
- 2. Studio가 처리하지 못한 연산자의 대체 경로와 추가 개발비는 얼마인가?
- 3. 계약은 일회성 개발비, 라이선스, 로열티를 어떻게 구분하는가?

비교·검증 축	실행할 확인
적합한 비교군	HyperAccel, Synthara
고객 PoC의 고정 조건	목표 공정·면적·모델·검증 조건
결과 판정	PPA·통합 기간·지원 연산을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

AiM Future은(는) AI 반도체 IP 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S025 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

BOS Semiconductors

C07 | 국내 | 자동차 · Physical AI

기업 · 사업 근거 | 공개 자료

자동차와 Physical AI용 칩렛 제품군을 공개합니다. 제품 페이지는 Eagle-N을 250 INT8 TOPS dense, Eagle-A를 150 TOPS dense로 소개합니다. 두 제품의 양산 목표는 각각 2027년과 2028년으로 표시됩니다. [S026]

핵심 기술 | 공개 자료

Eagle-N은 RISC-V 기반 프로그래머블 코어, PCIe Gen5, UCIe, LPDDR5X를 소개합니다. Eagle-A는 CPU · GPU · NPU와 센서 인터페이스를 통합하는 ADAS SoC입니다. 사양표의 안전 관련 표시는 인증 보고서 원본과 구분합니다. [S026]

필드	조사 기록
제품 · 기술	Eagle-N / Eagle-A
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	자동차 OEM · Tier 1 · 로봇 플랫폼
측정할 조건	차량 응용 · 센서 · 온도 · deadline
평가 지표	실시간 지연 · 오류 격리 · 검증 단계
시스템 경계	차량 ECU · 호스트 · NPU

탐색 태그

BOS Semiconductors, Eagle-N / Eagle-A, 자동차 OEM · Tier 1 · 로봇 플랫폼

근거: S026. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용 · 시장 분석은 별도 가설입니다.

BOS Semiconductors | 시장성과 확인 과제

C07 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

기존 차량 프로세서에 AI 연산을 더하거나 칩렛 조합으로 차종별 성능을 조정하려는 수요에 연결됩니다. 단일 칩 사양보다 장기간의 차량 플랫폼 채택과 시스템 검증이 사업 가치를 좌우할 수 있습니다.

한계·도입 위험 | 분석·미확인

자동차 설계 채택은 양산까지 긴 시간이 걸릴 수 있습니다. 공개 일정은 목표이며 납품·인증 완료·수익 인식으로 취급하지 않습니다. 호스트와 칩렛의 결합 책임도 확인해야 합니다.

기업별 확인 질문

- 1. 고객 차량의 SOP 일정과 칩 샘플·인증·양산 일정이 맞는가?
- 2. 센서 입력부터 판단까지의 지연을 혼합 부하에서 만족하는가?
- 3. 안전 기능과 오류 격리의 시험 보고서 및 고객 검증 범위는 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	동일 고객 문제를 해결하는 기존 시스템과 비교
고객 PoC의 고정 조건	차량 응용·센서·온도·deadline
결과 판정	실시간 지연·오류 격리·검증 단계를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

BOS Semiconductors은(는) 자동차·Physical AI 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S026 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Panmnesia

C08 | 국내 | 연결·메모리 인프라

기업·사업 근거 | 공개 자료

CXL 기반 연결과 메모리 구성 기술을 제공하는 국내 기업입니다. 공개 페이지는 CXL 3.2와 포트 기반 라우팅을 지원하는 스위치 실리콘, 컨트롤러 IP 및 소프트웨어를 소개합니다. [S027]

핵심 기술 | 공개 자료

계산·메모리 자원을 연결하고 풀링·공유하는 fabric이 핵심입니다. 직접 신경망의 행렬 곱을 수행하는 NPU와 구별되는 AI 인프라 인접 기술입니다. 메모리 용량 확대와 접근 지연의 교환관계가 평가 대상입니다. [S027]

필드	조사 기록
제품·기술	PanSwitch / PanFabric
기업 상태	인접 분야 / 연결·메모리 반도체
주요 고객 가설	AI 서버·메모리 확장 장치·데이터센터 OEM
측정할 조건	토폴로지·트래픽·메모리 배치
평가 지표	유효 대역폭·p99 지연·복구
시스템 경계	스위치·링크·호스트·메모리

탐색 태그

Panmnesia, PanSwitch / PanFabric, AI 서버·메모리 확장 장치·데이터센터 OEM

근거: S027. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Panmnesia | 시장성과 확인 과제

C08 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

메모리 부족이나 자원 이용률이 낮은 시스템에서 후보가 됩니다. 연산기 교체 없이 자원 구성을 바꿀 수 있는지, 유휴 메모리를 줄인 편익이 fabric 도입 비용을 넘는지가 구매 근거입니다.

한계·도입 위험 | 분석·미확인

원격 메모리 지연과 소프트웨어 호환성 때문에 모든 AI 부하가 개선되지는 않습니다. 표준 지원과 상호운용 실증은 별도 증거이며, 표준 채택이 곧 고객 매출은 아닙니다.

기업별 확인 질문

- 1. 로컬 메모리·CXL 메모리 배치별 p99 지연과 처리량은 어떻게 변하는가?
- 2. 어떤 CPU·서버·운영체제 조합에서 상호운용을 검증했는가?
- 3. 용량 확장 편익을 스위치·컨트롤러·운영 비용까지 포함해 계산했는가?

비교·검증 축	실행할 확인
적합한 비교군	Enfabrica
고객 PoC의 고정 조건	토폴로지·트래픽·메모리 배치
결과 판정	유휴 대역폭·p99 지연·복구를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Panmnesia은(는) 연결·메모리 인프라 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S027 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

d-Matrix

C09 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

Corsair 추론 플랫폼과 관련 소프트웨어·인터넥트를 제공합니다. 2025년 11월 회사는 2억 7,500만 달러 Series C 유치를 발표했습니다. 2026년 6월에는 Corsair의 본격 생산 및 우선 고객 대상 출하 계획을 발표했습니다. [S012, S013, S014]

핵심 기술 | 공개 자료

Corsair는 SRAM 기반 디지털 인메모리 컴퓨트 칩렛 접근을 사용합니다. 생산 발표는 TSMC N6, 유기 기판, LPDDR5를 설명하며, 해당 구조를 HBM 기반 CoWoS 패키징과 구별합니다. [S014] 회사는 GPU와 Corsair를 함께 사용하는 분리 추론을 제시하며 prefill과 decode의 역할을 나눕니다. 제품 페이지에 소개된 차세대 3D DRAM 로드맵을 현행 Corsair의 메모리 구성으로 혼합하지 않습니다. [S012, S014]

필드	조사 기록
제품·기술	Corsair
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	기업 AI 인프라·클라우드 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

SRAM 기반 LLM 추론, GPU와 병용하는 decode 가속기, 저지연 추론 스타트업

근거: S012 · S013 · S014. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

d-Matrix | 시장성과 확인 과제

C09 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

지연이 중요한 대화형 AI, 코드 생성, 음성 서비스의 decode 비용을 줄이려는 수요가 사업 가설입니다. 기존 GPU 인프라와 병용할 경우 도입 범위를 단계적으로 잡을 수 있지만 실제 통합 비용이 관건입니다.

한계·도입 위험 | 분석·미확인

통신·스케줄링 오버헤드, 요청 길이와 동시성에 따른 손익분기점, 소프트웨어 지원, 장기 공급 조건을 확인해야 합니다. 생산 개시 발표를 출하량·가동률·매출의 증거로 바꾸지 않습니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. GPU 단독과 혼합 구성의 동일 서비스 수준을 비교합니다. GPU·Corsair·네트워크·호스트 전체의 비용과 전력을 포함하고, 낮은 이용률에서도 경제성이 유지되는지 확인합니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, Tenstorrent
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

d-Matrix은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S012 · S013 · S014 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Tenstorrent

C10 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

AI 컴퓨터·가속기와 개발 도구를 제공합니다. 2023년 공식 제휴 발표는 토론토 본사 및 북미 기반 기업으로 설명합니다. 현재 투자 대상 법인의 소재와 최신 투자 라운드는 이번 조사에서 확정하지 않았습니다. [S015, S017]

핵심 기술 | 공개 자료

Deploy 페이지는 Blackhole 기반 Galaxy 시스템과 공랭 방식, 확장 연결을 소개합니다. 개발자 페이지는 오픈소스 SDK 경로를 제공합니다. 공개 소프트웨어 접근성을 실제 모델 지원 완성도와 동일시하지 않습니다. [S015, S016]
2023년 BOS와의 발표는 Tensix AI 코어를 자동차 SoC에 라이선스하는 협력을 설명합니다. 과거 IP 계약 발표는 해당 고객 제품의 현재 양산·매출을 직접 입증하지 않습니다. [S017]

필드	조사 기록
제품·기술	Blackhole / Tensix
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	기업 AI 인프라·클라우드 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

오픈소스 SDK AI 칩, AI 코어 라이선스, 확장형 AI 서버

근거: S015 · S016 · S017. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Tenstorrent | 시장성과 확인 과제

C10 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

자체 AI 인프라를 조정하려는 개발팀과 AI 코어를 통합하려는 칩 설계사를 별도 고객군으로 볼 수 있습니다. 시스템 판매와 IP 라이선스는 채택 주기와 수익 구조가 다르므로 하나의 매출 모델로 합치지 않습니다.

한계·도입 위험 | 분석·미확인

사용할 SDK 경로, 모델별 정확도·성능, 운영 모니터링, 지원 계약, 시스템 규모별 통신 효율을 확인해야 합니다. IP 사업은 통합 공정, 검증 책임과 장기 지원 조건을 별도로 검토합니다.

기업별 확인 질문

- 1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
- 2. 모델 포팅을 실제로 수행해 개발 시간과 성능을 함께 기록합니다. SDK가 공개되어 있다는 사실만으로 이전 비용이나 유지보수 부담이 낮다고 단정하지 않습니다.
- 3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Tenstorrent은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S015 · S016 · S017 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Etched

C11 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

칩·랙·소프트웨어를 함께 설계하는 추론 시스템 기업입니다. 2026년 8월 회사는 Jane Street에 첫 랙을 출하했고 7억 달러를 조달했다고 발표했습니다. 해당 발표는 라운드의 알파벳 명칭을 명시하지 않습니다. [S018, S019]

핵심 기술 | 공개 자료

2026년 6월 기술 발표는 TSMC N4P A0 실리콘, Low Voltage Inference와 Cluster Scale Memory, HBM·SRAM을 결합하는 메모리 접근을 설명합니다. 초기 고객 검증 상태라는 발표 시점의 맥락을 보존합니다. [S018] 회사는 MoE·긴 문맥 추론을 위한 클러스터 구성과 전용 연결을 설명합니다. 6월 발표의 10억 달러 계약 주장을 이미 인식한 매출로 표기하지 않습니다. [S018]

필드	조사 기록
제품·기술	추론 클러스터
기업 상태	공개 사업 확인 / 최신 법인·자본 상태 별도 확인
주요 고객 가설	기업 AI 인프라·클라우드 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

추론 전용 클러스터 스타트업, MoE 추론 시스템, HBM SRAM 결합 가속기

근거: S018 · S019. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Etched | 시장성과 확인 과제

C11 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

큰 모델을 낮은 지연으로 운영하려는 고객에게 칩과 시스템의 공동 설계가 차별화 가설이 될 수 있습니다. 첫 랙 출하는 사업 진행의 신호지만 여러 고객에게 재현 가능한 운영 성능을 뜻하지는 않습니다.

한계·도입 위험 | 분석·미확인

모델 변화 대응, 시스템 가용성, 장기 열·전력 특성, 고객 수와 계약 조건을 확인해야 합니다. 첫 고객이 투자 라운드도 주도했다는 발표를 고려하면 독립 고객의 검증과 매출 분산을 추가로 확인하는 것이 유용합니다. [S019; 분석]

기업별 확인 질문

1. 실제 유상 고객과 반복 구매를 입증할 수 있는가?
2. 구매 가능한 구성과 고객 검증 범위를 확인하고 실제 모델별 장시간 테스트를 수행합니다. 초기 실리콘, 랙 출하, 일반 판매와 매출 인식 상태를 서로 다른 이벤트로 저장합니다.
3. 다음 제품 세대로 기존 모델과 SDK를 이전할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Etched은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S018 · S019 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Hailo

C12 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

엣지 AI 가속기와 영상 프로세서 제품군을 제공합니다. 공개 제품 목록은 Hailo-8 26 TOPS, Hailo-8L 13 TOPS, Hailo-10H 40 TOPS INT4를 제시합니다. 숫자의 정밀도 조건이 다르면 직접 순위를 만들 수 없습니다. [S028]

핵심 기술 | 공개 자료

M.2·PCIe·mPCIe 형태의 가속 모듈과 Hailo-15 영상 프로세서를 구분합니다. Dataflow Compiler, HailoRT, Model Zoo가 배포 경로입니다. 영상 처리와 생성형 모델 지원은 제품 세대별로 확인해야 합니다. [S028]

필드	조사 기록
제품·기술	Hailo-8 / Hailo-10H / Hailo-15
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	스마트 카메라·산업용 PC·로봇 OEM
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

Hailo, Hailo-8 / Hailo-10H / Hailo-15, 스마트 카메라·산업용 PC·로봇 OEM

근거: S028. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Hailo | 시장성과 확인 과제

C12 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

기존 호스트의 확장 슬롯에 추론 기능을 더하려는 고객에게 모듈 형태가 유용할 수 있습니다. 다양한 제품군은 전력·원가 조건별 설계 선택을 넓히지만 구매자는 자신의 모델에 맞는 세대를 골라야 합니다.

한계·도입 위험 | 분석·미확인

구세대 가속기의 영상 지원을 신세대의 LLM 지원과 혼합하면 검색 오류가 발생합니다. 모듈 메모리, 호스트 전처리, 변환 가능한 연산자와 실제 모델 정확도를 검증해야 합니다.

기업별 확인 질문

- 1. 목표 모델이 해당 제품의 compiler와 runtime 조합에서 변환되는가?
- 2. 다중 카메라 부하에서 호스트 CPU가 병목이 되지 않는가?
- 3. INT4 생성형 모델의 품질과 context 한계를 원본 모델과 비교했는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Kneron
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Hailo은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S028 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Kneron

C13 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

장치 내부와 온프레미스 AI를 위한 NPU, 소프트웨어 및 시스템을 소개합니다. 홈페이지는 스마트 차량·보안·가정·엣지 서버 응용과 KNEO 플랫폼을 제시합니다. [S029]

핵심 기술 | 공개 자료

회사는 칩부터 운영 환경·추론 소프트웨어까지 제공하는 접근을 설명합니다. 전체 제품군의 보안·저지연 홍보 문구를 특정 SoC의 인증이나 실측값으로 옮기지 않습니다. 칩 이름과 서버 이름을 별도 엔터티로 관리합니다. [S029]

필드	조사 기록
제품·기술	NPU / KNEO
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	보안 장비·스마트 기기·온프레미스 AI 고객
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

Kneron, NPU / KNEO, 보안 장비·스마트 기기·온프레미스 AI 고객

근거: S029. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Kneron | 시장성과 확인 과제

C13 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

데이터를 외부로 전송하기 어려운 현장의 AI 기능을 현지에서 실행하려는 요구에 대응할 수 있습니다. 하드웨어와 앱을 함께 판매하는 경우 칩 가격 외에 구축·유지보수 매출 구조를 파악해야 합니다.

한계·도입 위험 | 분석·미확인

제품 범위가 넓어 어느 부문의 유상 수요가 가장 큰지 공개 홈페이지만으로 알 수 없습니다. 인터넷 비의존성은 패치·인증·라이선스 정책까지 자동 보장하지 않습니다.

기업별 확인 질문

- 1. 오프라인 운용 중 모델 업데이트와 장애 대응을 어떻게 수행하는가?
- 2. 칩·장치·서버 중 고객이 구매하는 SKU와 보증 범위는 무엇인가?
- 3. 클라우드 전송 감소가 고객 비용과 응답시간에 얼마나 기여하는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Kneron은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S029 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Axelera AI

C14 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

Metis·Europa AIPU와 Titania 칩렛 로드맵을 공개합니다. 현행 페이지는 Metis 214 TOPS·평균 4-8W, Europa 629 TOPS·평균 45W를 제시합니다. 이는 회사 공개값이며 정밀도·희소성·모델 조건을 추가 확인해야 합니다. [S030]

핵심 기술 | 공개 자료

Metis는 소형 엣지, Europa는 무거운 엣지·기업 서버, Titania는 더 큰 시스템을 지향합니다. 제품군은 디지털 인메모리 연산 접근과 Voyager 도구를 연결합니다. 서로 다른 발표 시점의 TOPS를 덮어쓰지 않습니다. [S030]

필드	조사 기록
제품·기술	Metis / Europa / Voyager
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	산업 비전·엣지 서버·기업 AI 인프라 OEM
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

Axelera AI, Metis / Europa / Voyager, 산업 비전·엣지 서버·기업 AI 인프라 OEM

근거: S030. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Axelera AI | 시장성과 확인 과제

C14 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

현장 추론에서 서버까지 확장하려는 고객에게 동일 도구 흐름이 도입 편익이 될 수 있습니다. 한 제품에서 검증한 모델이 다른 제품에서도 같은 품질로 동작하는지가 확장 판매를 결정합니다.

한계·도입 위험 | 분석·미확인

Titania 로드맵의 성능을 현행 판매 제품에 합산하면 안 됩니다. 홈페이지의 평균 전력과 고객 시스템 전체 소비전력은 다르며, 신제품의 실제 가용성과 안정성을 확인해야 합니다.

기업별 확인 질문

- 1. Metis에서 Europa로 이전할 때 모델 재양자화와 코드 수정이 필요한가?
- 2. 개별 카드의 메모리 용량과 대역폭이 고객 모델을 수용하는가?
- 3. 공개 TOPS의 정밀도·회소성 조건과 실제 영상·LLM 처리량을 제시하는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Axelera AI은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S030 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SiMa.ai

C15 | 해외 | 엣지 AI · 영상 계산

기업 · 사업 근거 | 공개 자료

Modalix MLSoC와 SoM · PCIe 카드 · 개발 키트를 제공합니다. 공식 페이지는 50 TOPS와 10W 미만의 전력 표현, CNN · ViT · LLM · LMM 지원을 소개합니다. [S031]

핵심 기술 | 공개 자료

ML 가속기만이 아니라 센서 입출력과 전후처리를 포함한 이종 연산 SoC를 강조합니다. BF16 · INT8 · INT16 정밀도와 MIPI · USB · PCIe 등의 인터페이스가 제시됩니다. Palette가 소프트웨어 배포 도구입니다. [S031]

필드	조사 기록
제품 · 기술	Modalix MLSoC / Palette
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	로봇 · 드론 · 산업 장비 개발사
측정할 조건	센서 수 · 해상도 · 모델 · 온도
평가 지표	정확도 · 프레임 지연 · 지속 성능
시스템 경계	가속기 · 호스트 · 센서 · 방열

탐색 태그

SiMa.ai, Modalix MLSoC / Palette, 로봇 · 드론 · 산업 장비 개발사

근거: S031. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용 · 시장 분석은 별도 가설입니다.

SiMa.ai | 시장성과 확인 과제

C15 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

전체 영상·센서 파이프라인을 작은 모듈에서 처리하려는 수요에 연결됩니다. 기존 캐리어 보드 활용은 기구·회로 변경을 줄일 가능성이 있지만 인터페이스와 소프트웨어 검증이 선행되어야 합니다.

한계·도입 위험 | 분석·미확인

핀 호환이라는 표현이 모든 보드·드라이버·열 설계의 완전한 교체 호환성을 뜻하지는 않습니다. 가속기 성능보다 CPU와 센서 입력을 포함한 전체 처리 시간을 확인해야 합니다.

기업별 확인 질문

- 1. 센서 캡처·전처리·추론·후처리의 단계별 실행 위치와 지연은 무엇인가?
- 2. 기존 SoM 캐리어의 전원·핀·인터페이스가 실제로 호환되는가?
- 3. CPU fallback을 포함해 10W 미만 표현의 측정 조건이 재현되는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SiMa.ai은(는) 옛지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S031 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

MemryX

C16 | 해외 | 옛지 AI·영상 계산

기업·사업 근거 | 공개 자료

추론 가속기 MX3 및 Cascade 모듈과 후속 제품군을 소개합니다. 회사는 2019년 Ann Arbor에서 설립되었다고 밝히며 산업 비전·영상 분석·교통 시스템을 응용으로 제시합니다. [S032]

핵심 기술 | 공개 자료

데이터를 연산 가까이에 두고 준비된 데이터가 흐르도록 하는 dataflow 구조를 설명합니다. M.2·PCIe·USB 등 모듈과 공개 개발자 도구를 제공합니다. MX3의 배포 이력을 MX4의 상용화 상태로 옮기지 않습니다. [S032]

필드	조사 기록
제품·기술	MX3 / Cascade / MX4
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	영상 분석 솔루션사·산업용 PC 통합사
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

MemryX, MX3 / Cascade / MX4, 영상 분석 솔루션사·산업용 PC 통합사

근거: S032. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

MemryX | 시장성과 확인 과제

C16 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

다수의 영상 스트림을 일정한 처리 속도로 분석하려는 고객에 적합한 탐색 후보입니다. 여러 인터페이스는 도입 경로를 넓히지만 사용자 모델의 컴파일과 호스트 병목을 함께 검토해야 합니다.

한계·도입 위험 | 분석·미확인

가속기 파이프라인에 맞지 않는 모델과 동적 연산에서 성능이 달라질 수 있습니다. 자동 컴파일 주장이 실제 모델의 변환 성공률과 유지보수 비용을 대체하지 않습니다.

기업별 확인 질문

- 1. 카메라 수를 늘릴 때 지연과 누락 프레임이 선형적으로 유지되는가?
- 2. 모델 컴파일 실패 시 개발자가 수정해야 하는 연산은 무엇인가?
- 3. USB·M.2·PCIe 구성의 성능·열·호스트 차이를 검증했는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

MemryX은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S032 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Syntiant

C17 | 해외 | 상시 동작 센서 AI

기업·사업 근거 | 공개 자료

상시 동작하는 엣지 AI용 Neural Decision Processor, 모델 및 센서 제품을 제공합니다. 음성·오디오·센서·비전 응용을 통합하는 접근을 소개합니다. [S033]

핵심 기술 | 공개 자료

회사 설명은 at-memory compute로 데이터 이동을 줄이는 설계를 강조합니다. 신경망 모델·학습 도구·하드웨어 최적화와 MEMS 마이크·진동 센서를 함께 다룹니다. 출하량 홍보 주장은 외부 감사 매출과 구분합니다. [S033]

필드	조사 기록
제품·기술	Neural Decision Processor
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	이어버드·웨어러블·센서 장치 제조사
측정할 조건	사건 빈도·소음·배터리·모델
평가 지표	오탐·미탐·이벤트당 에너지
시스템 경계	센서·AI 칩·호스트·무선

탐색 태그

Syntiant, Neural Decision Processor, 이어버드·웨어러블·센서 장치 제조사

근거: S033. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Syntiant | 시장성과 확인 과제

C17 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

배터리를 유지하면서 항상 신호를 감지해야 하는 기기에 수요가 있습니다. 호스트를 불필요하게 깨우지 않는 성능이 중요하며, 칩 단품보다 센서·모델·도구의 공동 검증이 채택 장벽을 낮출 수 있습니다.

한계·도입 위험 | 분석·미확인

경량 모델의 성능을 큰 생성형 모델 능력으로 확대하지 않습니다. 마이크 환경, 사용자 언어, 오탐에 따른 호스트 기동 전력까지 봐야 합니다.

기업별 확인 질문

- 1. 키워드 탐지의 오탐·미탐을 소음·언어·거리별로 공개하는가?
- 2. 대기 전력과 이벤트 처리 전력, 호스트 기동 전력을 따로 측정했는가?
- 3. 칩·모델·센서 각각의 단가와 공급 계약 책임은 어떻게 나뉘는가?

비교·검증 축	실행할 확인
적합한 비교군	Ambient Scientific, AONDevices
고객 PoC의 고정 조건	사건 빈도·소음·배터리·모델
결과 판정	오탐·미탐·이벤트당 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Syntiant은(는) 상시 동작 센서 AI 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이 나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S033 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Ambient Scientific

C18 | 해외 | 상시 동작 센서 AI

기업·사업 근거 | 공개 자료

팍리스 기업으로 GPX10과 DigAn 기술을 소개합니다. 상시 동작 센서 융합, 음성 명령 및 저빈도 비전 응용을 대상으로 제시합니다. [S034]

핵심 기술 | 공개 자료

아날로그 행렬 연산, 저전력 SRAM과 ADC를 결합하는 접근입니다. 자체 AI 코어·컴파일러·SDK와 여러 비트 폭의 연산 지원을 설명합니다. 코인셀 수년 운용 주장은 이벤트 빈도·센서·배터리 조건을 확인해야 합니다. [S034]

필드	조사 기록
제품·기술	GPX10 / DigAn
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	배터리 센서·웨어러블·저전력 IoT OEM
측정할 조건	사건 빈도·소음·배터리·모델
평가 지표	오탐·미탐·이벤트당 에너지
시스템 경계	센서·AI 칩·호스트·무선

탐색 태그

Ambient Scientific, GPX10 / DigAn, 배터리 센서·웨어러블·저전력 IoT OEM

근거: S034. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Ambient Scientific | 시장성과 확인 과제

C18 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

연속 신호를 해석하면서 무선 전송을 최소화하는 장치에서 후보가 됩니다. 배터리 교체가 비싼 설치 환경이면 전력 절감의 고객 편익이 칩 단가 차이보다 클 수 있습니다.

한계·도입 위험 | 분석·미확인

아날로그 연산은 온도·편차·변환 회로를 포함한 정확도 검증이 필요합니다. 낮은 빈도의 영상 사례를 고해상도 실시간 영상 처리로 일반화하지 않습니다.

기업별 확인 질문

- 1. 온도와 공급전압 변화에서 센서 모델의 정확도는 유지되는가?
- 2. ADC·센서·무선 모듈까지 포함한 장치 배터리 수명은 얼마인가?
- 3. 고객 고유 모델의 컴파일·교정 과정은 얼마나 반복 가능한가?

비교·검증 축	실행할 확인
적합한 비교군	Syntiant, AONDevices
고객 PoC의 고정 조건	사건 빈도·소음·배터리·모델
결과 판정	오탐·미탐·이벤트당 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Ambient Scientific은(는) 상시 동작 센서 AI 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S034 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

AONDevices

C19 | 해외 | 상시 동작 센서 AI

기업·사업 근거 | 공개 자료

음성·소리·동작 센서를 위한 상시 동작 AI 칩과 모델 개발 도구를 소개합니다. AONx360은 데이터 수집·증강·학습·시험·배포 흐름을 다룹니다. [S035]

핵심 기술 | 공개 자료

음성 명령 외에 음향 이벤트·장면·화자·동작 인식을 대상으로 합니다. 공식 페이지에는 특정 처리 조건에서 260μW 미만 전력 표현이 있으나 전체 장치 소비전력으로 취급하지 않습니다. [S035]

필드	조사 기록
제품·기술	AON11xx / AONx360
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	스마트홈·리모컨·웨어러블·음향 장치 제조사
측정할 조건	사건 빈도·소음·배터리·모델
평가 지표	오탐·미탐·이벤트당 에너지
시스템 경계	센서·AI 칩·호스트·무선

탐색 태그

AONDevices, AON11xx / AONx360, 스마트홈·리모컨·웨어러블·음향 장치 제조사

근거: S035. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

AONDevices | 시장성과 확인 과제

C19 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

단순 문턱값 센서가 만드는 오경보를 줄이고 호스트·무선 통신을 선택적으로 깨우는 수요에 연결됩니다. 고객은 모델 정확도와 함께 원치 않는 기동이 줄어드는지를 확인해야 합니다.

한계·도입 위험 | 분석·미확인

평균 정확도만으로 실제 오탐 부담을 알 수 없습니다. 소음 종류와 사건 발생 빈도에 따라 사용자 경험과 배터리 편익이 달라집니다.

기업별 확인 질문

- 1. 일상 생활 소음에서 시간당 오탐 횟수는 얼마인가?
- 2. 학습에 없는 사용자·방·마이크에서도 사건 탐지가 유지되는가?
- 3. 칩 전력보다 큰 무선 기동 전력 감소 효과를 분리해 측정했는가?

비교·검증 축	실행할 확인
적합한 비교군	Syntiant, Ambient Scientific
고객 PoC의 고정 조건	사건 빈도·소음·배터리·모델
결과 판정	오탐·미탐·이벤트당 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

AONDevices은(는) 상시 동작 센서 AI 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S035 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

EdgeCortix

C20 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

Physical AI용 저전력 가속기와 소프트웨어를 소개합니다. 홈페이지는 단일 가속기부터 다이 여러 개를 사용하는 플랫폼까지 하나의 구조와 도구를 연결한다고 설명합니다. [S036]

핵심 기술 | 공개 자료

MERA 컴파일러와 Dynamic Neural Accelerator, SAKURA-II 등의 제품 경로를 제공합니다. 모델 변화 대응과 시스템 확장을 강조하지만 제품별 연산자·모델 목록을 확인해야 합니다. [S036]

필드	조사 기록
제품·기술	SAKURA / MERA / RAIDEN
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	로봇·임베디드·산업용 엣지 시스템 개발사
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

EdgeCortix, SAKURA / MERA / RAIDEN, 로봇·임베디드·산업용 엣지 시스템 개발사

근거: S036. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

EdgeCortix | 시장성과 확인 과제

C20 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

현장 전력 제약 안에서 큰 모델을 운영하려는 수요의 후보입니다. IP와 도구를 같이 제공하는 사업은 칩 판매뿐 아니라 고객 설계와 시스템 통합으로 확장될 가능성이 있습니다.

한계·도입 위험 | 분석·미확인

여러 지역의 협력·실증 발표는 일반 산업 고객의 반복 구매와 구분합니다. 엣지 제품과 다이 확장 플랫폼의 성능을 같은 사양으로 기록하지 않습니다.

기업별 확인 질문

- 1. 현재 구매 가능한 보드에서 목표 모델의 메모리와 지연 한계를 측정했는가?
- 2. MERA가 지원하는 프레임워크·연산자·양자화 버전은 무엇인가?
- 3. 단일 가속기에서 다이 여러 개로 늘릴 때 통신 비용이 얼마나 발생하는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

EdgeCortix은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S036 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

NEUCHIPS

C21 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

온프레미스 LLM용 AI 추론 ASIC, PCIe 카드, 통합 소프트웨어를 제공합니다. 홈페이지는 N3000과 Viper 카드 및 IP 라이선스·설계 서비스 확장을 소개합니다. [S037]

핵심 기술 | 공개 자료

7nm ASIC 설계와 컴파일러·드라이버·프레임워크·추론 엔진을 연결합니다. 추천 모델 DLRM 관련 효율 주장을 LLM 전체에 그대로 적용하지 않습니다. 단일 카드의 모델 크기·전력 주장은 양자화 조건을 확인해야 합니다. [S037]

필드	조사 기록
제품·기술	Raptor N3000 / Viper
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	기업 내부 AI 서버·시스템 통합사·ASIC 고객
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

NEUCHIPS, Raptor N3000 / Viper, 기업 내부 AI 서버·시스템 통합사·ASIC 고객

근거: S037. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

NEUCHIPS | 시장성과 확인 과제

C21 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

사내 문서·데이터베이스를 외부로 보내지 않고 질의하려는 고객에 맞는 후보입니다. 서버·지식 서비스 파트너십은 완성 솔루션 판매 경로가 될 수 있으나 칩 매출 기여를 따로 확인해야 합니다.

한계·도입 위험 | 분석·미확인

과거 추천 시스템 성능과 현재 생성형 AI 역량을 구분해야 합니다. 칩 판매에서 설계 서비스로 사업을 넓히면 매출 구성과 개발 자원 배분이 달라질 수 있습니다.

기업별 확인 질문

- 1. RAG 파이프라인에서 검색·prefill·decode의 병목이 어디에 있는가?
- 2. 지원 모델의 정밀도·문맥 길이·동시성 조건이 문서화되었는가?
- 3. 카드 판매, 라이선스, 개발 용역의 계약과 매출 구조는 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
사업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

NEUCHIPS은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S037 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Mythic

C22 | 해외 | 메모리·연산 결합

기업·사업 근거 | 공개 자료

플래시 메모리에 모델 가중치를 저장하고 그 위치에서 아날로그 연산을 수행하는 APU를 소개합니다. 현행 사이트는 엠티부터 데이터센터까지의 칩렛 확장 방향과 2026년 1월 Videantis 인수를 설명합니다. [S038]

핵심 기술 | 공개 자료

메모리와 연산 사이의 반복 이동을 줄이는 구조가 차별화의 중심입니다. 사이트의 높은 효율·성능 배수는 회사 주장입니다. 시스템 경계, 모델, 데이터 형식이 없는 배수를 GPU 대비 보편적 우위로 저장하지 않습니다. [S038]

필드	조사 기록
제품·기술	APU / analog compute-in-memory
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	엠티 장치·자동차 AI·추론 시스템 개발사
측정할 조건	소자·정밀도·온도·교정
평가 지표	품질 유지·에너지·제조성
시스템 경계	변환 회로·연산 배열·호스트

탐색 태그

Mythic, APU / analog compute-in-memory, 엠티 장치·자동차 AI·추론 시스템 개발사

근거: S038. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Mythic | 시장성과 확인 과제

C22 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

고정 또는 천천히 바뀌는 모델을 에너지 효율적으로 반복 실행하는 수요를 검토할 수 있습니다. 차량 분야 경험의 결합이 제품 검증과 고객 접점을 넓힐 가능성이 있으나 인수 기업의 과거 탑재량과 신규 APU 출하량은 다릅니다.

한계·도입 위험 | 분석·미확인

아날로그 편차·교정·가중치 갱신·정확도가 핵심 검증점입니다. 칩렛 확장 계획과 실제 고객 구성의 차이를 확인해야 하며, 이전 제품의 실적을 차세대 제품에 그대로 전가하지 않습니다.

기업별 확인 질문

- 1. 온도·수명·개체 편차가 추론 정확도에 주는 영향을 측정했는가?
- 2. 가중치 업데이트 빈도와 교정 시간이 고객 운영에 맞는가?
- 3. 연산 배열 외 ADC·DAC·호스트를 포함한 시스템 효율은 얼마인가?

비교·검증 축	실행할 확인
적합한 비교군	SEMRON, REEXEN
고객 PoC의 고정 조건	소자·정밀도·온도·교정
결과 판정	품질 유지·에너지·제조성을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Mythic은(는) 메모리·연산 결합 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S038 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Innatera

C23 | 해외 | 뉴로모픽·희소 계산

기업·사업 근거 | 공개 자료

센서 엷지를 위한 뉴로모픽 프로세서 기업입니다. Pulsar를 뉴로모픽 마이크로컨트롤러로 소개하고 음성·동작·존재 감지와 로봇 반사 행동 등을 응용으로 제시합니다. [S039]

핵심 기술 | 공개 자료

스파이킹 신경망은 정보를 이산 이벤트로 처리합니다. 회사는 의미 있는 신호 변화에 반응하는 저전력 처리와 제어·조정 기능을 함께 강조합니다. dense 추론 기능과 SNN 경로는 각각 확인해야 합니다. [S039]

필드	조사 기록
제품·기술	Pulsar / spiking neural processor
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	센서 모듈·스마트홈·웨어러블 OEM
측정할 조건	이벤트 표현·희소성·목표 품질
평가 지표	사건별 지연·전체 에너지
시스템 경계	입력 변환·칩·후처리

탐색 태그

Innatera, Pulsar / spiking neural processor, 센서 모듈·스마트홈·웨어러블 OEM

근거: S039. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Innatera | 시장성과 확인 과제

C23 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

지속적으로 센서를 켜 두어야 하지만 실제 의미 있는 사건은 드문 환경에서 후보가 됩니다. 감지 기능을 장치 가까이 옮겨 네트워크 의존과 호스트 기동을 줄이는 편익을 평가할 수 있습니다.

한계·도입 위험 | 분석·미확인

일반 CNN을 기존 코드 그대로 실행할 수 있다고 가정하면 안 됩니다. 이벤트 인코딩·학습·디버깅 도구와 현장 잡음에 대한 성능을 함께 검증해야 합니다.

기업별 확인 질문

- 1. 실제 센서 신호를 이벤트로 바꾸는 과정에서 정보가 얼마나 손실되는가?
- 2. 평균 전력뿐 아니라 이벤트 폭증 때의 최대 지연을 측정했는가?
- 3. 기존 모델을 옮기는 학습·도구 비용이 배터리 편익보다 작은가?

비교·검증 축	실행할 확인
적합한 비교군	SynSense, SpiNNcloud, BrainChip
고객 PoC의 고정 조건	이벤트 표현·희소성·목표 품질
결과 판정	사건별 지연·전체 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Innatera은(는) 뉴로모픽·희소 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S039 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SynSense

C24 | 해외 | 뉴로모픽·희소 계산

기업·사업 근거 | 공개 자료

뉴로모픽 칩과 저전력·저지연 엣지 솔루션을 개발합니다. 회사는 2017년 설립, 2024년 iniVation 인수 및 중국·스위스의 연구개발 거점을 공개합니다. [S040]

핵심 기술 | 공개 자료

이벤트 기반 시각 센서와 뉴로모픽 연산을 결합하는 sense + compute 접근을 제시합니다. 지능형 상호작용·모니터링·차량 등을 대상으로 합니다. 센서와 추론 칩의 사양은 구분해 저장합니다. [S040]

필드	조사 기록
제품·기술	뉴로모픽 sense + compute
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	이벤트 비전·산업 감시·인터랙션 장치 개발사
측정할 조건	이벤트 표현·희소성·목표 품질
평가 지표	사건별 지연·전체 에너지
시스템 경계	입력 변환·칩·후처리

탐색 태그

SynSense, 뉴로모픽 sense + compute, 이벤트 비전·산업 감시·인터랙션 장치 개발사

근거: S040. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

SynSense | 시장성과 확인 과제

C24 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

빠른 움직임과 밝기 변화가 있는 장면에서 지연·데이터량을 줄이는 수요를 검토할 수 있습니다. 센서와 계산의 공동 설계는 통합 편익을 줄 수 있지만 기존 카메라 체계와의 교체 비용이 발생합니다.

한계·도입 위험 | 분석·미확인

정지 장면·저대비 신호에서의 한계와 이벤트 데이터셋 확보가 중요합니다. 협력·PoC 발표를 상용 제품 매출이나 전체 모델 지원으로 확대하지 않습니다.

기업별 확인 질문

- 1. 프레임 카메라 대비 실제 고객 사건 탐지의 정확도와 지연은 어떠한가?
- 2. 센서·칩·알고리즘을 별도 공급할 수 있는가, 결합 구매가 필요한가?
- 3. 이벤트 데이터 수집·라벨링·모델 유지보수 비용은 얼마인가?

비교·검증 축	실행할 확인
적합한 비교군	Innatera, SpiNNcloud, BrainChip
고객 PoC의 고정 조건	이벤트 표현·희소성·목표 품질
결과 판정	사건별 지연·전체 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SynSense은(는) 뉴로모픽·희소 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S040 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SpiNNcloud

C25 | 해외 | 뉴로모픽·희소 계산

기업·사업 근거 | 공개 자료

뇌에서 영감을 받은 계산 구조로 동적 희소 알고리즘의 효율적인 추론을 지향합니다. 회사는 시스템이 유럽과 미국의 연구기관에서 사용된다고 소개합니다. [S041]

핵심 기술 | 공개 자료

연산이 필요한 부분을 선택적으로 처리하는 동적 희소성과 확장형 시스템이 핵심입니다. 홈페이지의 에너지 효율 최상급 표현은 특정 고객 부하에서 실증할 주장으로 남깁니다. [S041]

필드	조사 기록
제품·기술	동적 희소성 추론 시스템
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	연구기관·희소 AI 알고리즘·특수 추론 인프라
측정할 조건	이벤트 표현·희소성·목표 품질
평가 지표	사건별 지연·전체 에너지
시스템 경계	입력 변환·칩·후처리

탐색 태그

SpiNNcloud, 동적 희소성 추론 시스템, 연구기관·희소 AI 알고리즘·특수 추론 인프라

근거: S041. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

SpiNNcloud | 시장성과 확인 과제

C25 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

기존 dense 연산으로 낭비가 큰 문제에서 특화 하드웨어의 가치가 생길 수 있습니다. 연구기관 채택은 기술 검증에 도움이 되지만 반복적인 상업 수요와 구매 예산은 별도 확인해야 합니다.

한계·도입 위험 | 분석·미확인

동적 희소성을 활용하지 못하는 모델에서는 기대 편익이 작을 수 있습니다. 알고리즘 재구성과 소프트웨어 이전이 필요한지, 고객의 실시간 제약에 적합한지 확인해야 합니다.

기업별 확인 질문

- 1. 목표 모델의 실제 활성 연산 비율은 얼마이며 입력에 따라 어떻게 바뀌는가?
- 2. dense 기준선과 같은 품질·문제 크기에서 에너지를 비교했는가?
- 3. 연구 장비 판매를 넘어 운영 지원·반복 주문이 발생하는가?

비교·검증 축	실행할 확인
적합한 비교군	Innatera, SynSense, BrainChip
고객 PoC의 고정 조건	이벤트 표현·희소성·목표 품질
결과 판정	사건별 지연·전체 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SpiNNcloud은(는) 뉴로모픽·희소 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S041 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Synthara

C26 | 해외 | AI 반도체 IP

기업·사업 근거 | 공개 자료

임베디드 칩에 인메모리 연산을 통합하는 ComputeRAM을 제공합니다. 회사는 보청기·웨어러블·음성 비서·로봇·스마트 센서 응용을 제시합니다. [S042]

핵심 기술 | 공개 자료

기존 메모리에서 데이터를 읽어 별도 계산기로 보내는 병목을 줄이려는 IP 접근입니다. 회사의 큰 성능·효율 배수는 지정 부하와 통합 조건이 있는 주장으로 처리합니다. [S042]

필드	조사 기록
제품·기술	ComputeRAM
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	MCU·센서 SoC·임베디드 반도체 설계사
측정할 조건	목표 공정·면적·모델·검증 조건
평가 지표	PPA·통합 기간·지원 연산
시스템 경계	IP·메모리·SoC·툴체인

탐색 태그

Synthara, ComputeRAM, MCU·센서 SoC·임베디드 반도체 설계사

근거: S042. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Synthara | 시장성과 확인 과제

C26 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

완성 가속기 카드를 도입하기 어려운 소형 장치의 기존 칩 설계를 확장하려는 수요에 연결됩니다. 고객이 쓰는 공정·메모리 컴파일러와 연결되고 설계 흐름을 크게 바꾸지 않는지가 중요합니다.

한계·도입 위험 | 분석·미확인

IP 특성값을 최종 SoC의 전체 성능으로 일반화하면 안 됩니다. 메모리 용량·연산 모드·검증 책임과 고객별 설계 지원 부담을 확인해야 합니다.

기업별 확인 질문

- 1. 목표 공정의 메모리 매크로와 검증된 통합 경로가 존재하는가?
- 2. 메모리 기능과 연산 기능을 동시에 쓸 때 제약은 무엇인가?
- 3. 실리콘 면적·마스크·개발비 증가를 포함한 고객 손익분기점은 어디인가?

비교·검증 축	실행할 확인
적합한 비교군	HyperAccel, AiM Future
고객 PoC의 고정 조건	목표 공정·면적·모델·검증 조건
결과 판정	PPA·통합 기간·지원 연산을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Synthara은(는) AI 반도체 IP 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S042 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SEMRON

C27 | 해외 | 메모리·연산 결합

기업·사업 근거 | 공개 자료

공식 사이트는 3D 플래시 내부에서 계산하는 3D CapRAM 기술을 소개합니다. 미국 Austin과 독일 Dresden의 채용 거점이 공개되어 있으며 성능 논문은 접근 요청 경로가 있습니다. [S043]

핵심 기술 | 공개 자료

공개 홈페이지의 설명 범위는 3차원 메모리 구조와 계산을 결합한다는 방향입니다. 접근 제한된 성능 논문의 결과를 읽은 것으로 취급하지 않으며 실제 처리량·전력·양산 상태를 미확인으로 남깁니다. [S043]

필드	조사 기록
제품·기술	3D CapRAM
기업 상태	기술 탐색 후보 / 공개 실측 근거 제한
주요 고객 가설	차세대 AI 가속기·메모리 집적 기술 고객
측정할 조건	소자·정밀도·온도·교정
평가 지표	품질 유지·에너지·제조성
시스템 경계	변환 회로·연산 배열·호스트

탐색 태그

SEMRON, 3D CapRAM, 차세대 AI 가속기·메모리 집적 기술 고객

근거: S043. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

SEMIRON | 시장성과 확인 과제

C27 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

평면 칩의 면적과 데이터 이동 제약을 줄일 수 있다면 고밀도 추론에 가치가 생길 수 있습니다. 현재는 검증된 고객 도입 보다 기술 실증 자료를 우선 확보해야 하는 후보로 분류합니다.

한계·도입 위험 | 분석·미확인

3D 적층의 열·수율·검사·정밀도와 제조 파트너 의존성이 중요합니다. 기술 아이디어의 장점과 생산 가능한 상용 칩의 경제성은 서로 다른 단계입니다.

기업별 확인 질문

- 1. 실제 실리콘에서 측정한 모델 정확도·전력·온도 데이터가 있는가?
- 2. 적층 수와 수율·테스트 비용의 관계를 확인할 수 있는가?
- 3. 공개 가능한 고객 샘플과 생산 일정은 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	Mythic, REEXEN
고객 PoC의 고정 조건	소자·정밀도·온도·교정
결과 판정	품질 유지·에너지·제조성을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SEMIRON은(는) 메모리·연산 결합 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이 나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S043 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Fractile

C28 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

메모리와 연산을 물리적으로 섞어 frontier 모델의 지연과 처리량을 함께 개선하려는 기업입니다. 홈페이지는 2026년 5월 2억 2,000만 달러 조달 소식을 연결합니다. [S044]

핵심 기술 | 공개 자료

트랜지스터 수준 회로부터 클라우드 추론 서버까지 공동 설계하는 접근을 설명합니다. 동시 사용자 수·토큰 속도에 대한 목표는 양산 제품의 독립 실측과 구별해야 합니다. [S044]

필드	조사 기록
제품·기술	메모리·연산 통합 추론 프로세서
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	프런티어 모델 개발사·대규모 추론 클라우드
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

Fractile, 메모리·연산 통합 추론 프로세서, 프런티어 모델 개발사·대규모 추론 클라우드

근거: S044. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Fractile | 시장성과 확인 과제

C28 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

긴 추론과 많은 동시 요청이 공존하는 서비스는 지연·처리량을 동시에 요구합니다. 아키텍처가 이 요구를 만족하면 프리미엄 응답 속도 시장과 대량 토큰 시장을 함께 겨냥할 수 있습니다.

한계·도입 위험 | 분석·미확인

공개 설명만으로 실제 메모리 구조·시제품 성숙도·고객 비용을 모두 알 수 없습니다. 자금 조달은 개발 여력을 보여 주지만 성능과 고객 채택의 대체 증거가 아닙니다.

기업별 확인 질문

- 1. 실제 칩에서 처리한 모델·정밀도·동시성 결과를 제시할 수 있는가?
- 2. 모델이 커질 때 메모리 배치와 칩 간 통신 비용은 어떻게 증가하는가?
- 3. 낮은 지연과 높은 처리량을 같은 실험에서 동시에 달성했는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Fractile은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S044 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

MatX

C29 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

큰 모델을 위한 칩을 개발하며 MatX One을 공개합니다. 학습·prefill에서는 연산 처리량, decode·강화학습에서는 지연과 긴 문맥 지원을 강조합니다. [S045]

핵심 기술 | 공개 자료

공식 소개는 가중치를 주로 SRAM에 두는 방식과 대규모 scale-out 연결, 하드웨어를 직접 제어하는 프로그래밍 모델을 설명합니다. 큰 MoE와 dense 모델 지원은 실제 모델·시스템 규모별 검증이 필요합니다. [S045]

필드	조사 기록
제품·기술	MatX One
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	대형 모델 연구소·학습 및 추론 인프라 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

MatX, MatX One, 대형 모델 연구소·학습 및 추론 인프라 운영사

근거: S045. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

MatX | 시장성과 확인 과제

C29 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

학습·추론을 별도 장비로 단절시키기보다 같은 인프라에서 활용하려는 고객이 후보입니다. 하드웨어 제어 가능성은 전문 팀의 최적화 여지를 주지만 작은 팀에게는 개발 부담이 될 수 있습니다.

한계·도입 위험 | 분석·미확인

SRAM 용량을 넘는 모델의 분할과 칩 간 연결이 경제성을 결정할 수 있습니다. 제시된 속도와 확장성은 공급 가능한 제품 및 독립 측정 여부를 확인해야 합니다.

기업별 확인 질문

- 1. 주요 가중치를 SRAM에 유지하려면 고객 모델에 몇 개의 칩이 필요한가?
- 2. 긴 문맥 KV cache가 늘어날 때 지연·메모리 배치는 어떻게 변하는가?
- 3. 프로그래밍 모델을 기존 프레임워크와 연결하는 엔지니어링 비용은 얼마인가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

MatX은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S045 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Positron

C30 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

현재 출하 제품과 2027년 예정인 Asimov 칩·시스템을 구분해 소개합니다. 현행 사이트는 Asimov 성능이 cycle-accurate simulation에 기반한다고 명시합니다. [S046]

핵심 기술 | 공개 자료

Transformer 추론과 큰 메모리 용량을 강조하고 모델 업로드·관리 및 호환 API 경로를 설명합니다. 시뮬레이션 기반 성능·매출 시나리오를 판매 제품의 실측 또는 실제 매출로 기록하지 않습니다. [S046]

필드	조사 기록
제품·기술	Atlas / Asimov
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	온프레미스 LLM·추론 서비스 사업자
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

Positron, Atlas / Asimov, 온프레미스 LLM·추론 서비스 사업자

근거: S046. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Positron | 시장성과 확인 과제

C30 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

큰 모델의 메모리 수용성과 사용자별 응답 속도가 중요한 서비스에서 후보입니다. API 경로의 호환성은 앱 변경을 줄일 가능성이 있지만 모델 지원과 운영 기능을 함께 확인해야 합니다.

한계·도입 위험 | 분석·미확인

Asimov의 예정 일정과 현행 장비의 성능을 혼합할 위험이 큼. 높은 응답 속도에 더 높은 가격을 받는 시나리오는 가정이며 고객의 실제 지불 의사를 검증해야 합니다.

기업별 확인 질문

- 1. 구매 가능한 현행 장비와 Asimov 시뮬레이션의 결과를 분리했는가?
- 2. 고객 요청 분포에서 메모리 용량 증가의 편익은 무엇인가?
- 3. 프리미엄 응답 속도에 추가 요금을 낼 고객 비율을 실증했는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Positron은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S046 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Tensordyne

C31 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

Recogni의 기존 도메인이 Tensordyne 사이트로 연결됩니다. 현행 사이트는 Napier 추론 시스템과 기존 비전 사업에서 데이터센터 추론으로의 집중을 설명합니다. [S047]

핵심 기술 | 공개 자료

로그 수학 기반 연산과 scale-up 인터커넥트를 강조하며 3nm Napier 테이프아웃 및 대량 생산 전환을 소개합니다. 과거 Scorpio의 샘플 실증과 Napier의 현재 검증 단계는 구분해야 합니다. [S047]

필드	조사 기록
제품·기술	Napier / Recogni 계보
기업 상태	브랜드·사업 변화 확인 / 법인 관계 추가 확인
주요 고객 가설	데이터센터 추론·대형 MoE 서비스 운영사
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

Tensordyne, Napier / Recogni 계보, 데이터센터 추론·대형 MoE 서비스 운영사

근거: S047. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Tensordyne | 시장성과 확인 과제

C31 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

모델 계산의 표현 방식과 시스템 연결을 함께 바꾸어 비용을 낮추려는 접근입니다. 기존 비전 고객의 실적보다 새 데이터센터 고객에게 유상으로 검증되는지가 더 직접적인 사업 지표입니다.

한계·도입 위험 | 분석·미확인

로그 연산의 수치 오차와 모델 품질, 커스텀 도구의 성숙도, 네트워크 확장의 재현성이 중요합니다. 명칭 변경의 법인·투자 관계는 공식 법인 자료로 추가 확인해야 합니다.

기업별 확인 질문

- 1. 로그 수학 변환 후 긴 문맥·MoE 모델의 품질이 유지되는가?
- 2. 테이프아웃·생산 전환·고객 출하의 날짜와 수량을 구분할 수 있는가?
- 3. 과거 Recogni와 현행 Tensordyne의 계약·IP·법인 관계는 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Tensordyne은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S047 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Esperanto Technologies

C32 | 해외 | RISC-V AI·HPC

기업·사업 근거 | 공개 자료

RISC-V 기반 AI·HPC 가속기를 제공합니다. 공개 소개는 TSMC 7nm ET-SoC-1에 1,000개 이상의 RISC-V 프로세서를 집적하고 생성형 AI·추천·비전·HPC를 대상으로 한다고 설명합니다. [S048]

핵심 기술 | 공개 자료

저전력 ET-Minion 코어에 텐서·벡터 연산을 결합하는 다수 코어 구조입니다. 표준 ISA의 활용과 실제 AI 라이브러리의 완성도는 구분합니다. 다음 세대 설계 계획은 현행 칩 성능에 포함하지 않습니다. [S048]

필드	조사 기록
제품·기술	ET-SoC-1
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	AI와 HPC 혼합 부하·연구기관·기업 서버
측정할 조건	코드·병렬성·벡터화·메모리
평가 지표	문제 해결 시간·에너지
시스템 경계	코어·메모리·통신·compiler

탐색 태그

Esperanto Technologies, ET-SoC-1, AI와 HPC 혼합 부하·연구기관·기업 서버

근거: S048. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Esperanto Technologies | 시장성과 확인 과제

C32 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

일반 수치 계산과 신경망 추론을 함께 운영하는 고객을 탐색할 수 있습니다. 워크로드를 여러 코어에 나눌 수 있다면 활용성이 생기지만 고객 코드의 병렬성이 실제 편익을 결정합니다.

한계·도입 위험 | 분석·미확인

많은 코어 수가 항상 높은 이용률을 뜻하지는 않습니다. 메모리 접근 패턴·동기화·컴파일러·통신을 포함한 전체 실행 시간을 확인해야 합니다.

기업별 확인 질문

- 1. AI와 HPC를 섞었을 때 단일 목적 가속기보다 자원 이용률이 높은가?
- 2. 고객 코드의 벡터화·병렬화에 추가 개발이 얼마나 필요한가?
- 3. 같은 문제 크기와 오차 허용도에서 실행 시간·에너지를 비교했는가?

비교·검증 축	실행할 확인
적합한 비교군	Openchip
고객 PoC의 고정 조건	코드·병렬성·벡터화·메모리
결과 판정	문제 해결 시간·에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Esperanto Technologies은(는) RISC-V AI·HPC 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S048 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Openchip

C33 | 해외 | RISC-V AI·HPC

기업·사업 근거 | 공개 자료

AI·HPC·엣지·데이터센터용 하드웨어·소프트웨어·시스템을 개발합니다. 공식 자료는 Barcelona Supercomputing Center를 설립 파트너로 소개하고 RISC-V 기반 유럽 계산 생태계를 강조합니다. [S049]

핵심 기술 | 공개 자료

RISC-V의 개방형 ISA를 기반으로 계산 솔루션을 설계하는 방향입니다. 공개 솔루션 페이지는 구체적 칩 사양이나 독립 벤치마크를 충분히 제공하지 않아 숫자 비교에서는 제외합니다. [S049]

필드	조사 기록
제품·기술	RISC-V 가속기·통합 스택
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	유럽 연구기관·HPC·주권형 AI 인프라
측정할 조건	코드·병렬성·벡터화·메모리
평가 지표	문제 해결 시간·에너지
시스템 경계	코어·메모리·통신·compiler

탐색 태그

Openchip, RISC-V 가속기·통합 스택, 유럽 연구기관·HPC·주권형 AI 인프라

근거: S049. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Openchip | 시장성과 확인 과제

C33 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

지역 내 설계 역량과 소프트웨어 주도권을 원하는 구매자에게 전략적 의미가 있을 수 있습니다. 공공 연구개발 지원과 고객의 지속적 구매 예산은 별도로 검증해야 합니다.

한계·도입 위험 | 분석·미확인

개방형 ISA는 성능·소프트웨어 호환·공급망 독립을 자동 보장하지 않습니다. 시제품, 톨체인, 제조·패키징 경로와 상용화 일정이 필요합니다.

기업별 확인 질문

- 1. 어떤 칩과 SDK를 현재 외부 고객이 평가할 수 있는가?
- 2. HPC 코드와 AI 모델을 옮기는 데 필요한 컴파일러·라이브러리가 준비되었는가?
- 3. 지원금 이후 고객이 반복 구매할 수 있는 제품·가격 구조가 있는가?

비교·검증 축	실행할 확인
적합한 비교군	Esperanto Technologies
고객 PoC의 고정 조건	코드·병렬성·벡터화·메모리
결과 판정	문제 해결 시간·에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Openchip은(는) RISC-V AI·HPC 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이 나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S049 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SiPearl

C34 | 해외 | HPC·AI 호스트 CPU

기업·사업 근거 | 공개 자료

유럽의 HPC·AI용 CPU를 설계합니다. Rhea1은 80개 Arm Neoverse V1 코어, 코어당 256비트 SVE 유닛 2개, HBM 4스택·DDR5·PCIe Gen5를 공개합니다. [S050]

핵심 기술 | 공개 자료

GPU·AI 가속기와 함께 쓰는 CPU로 직접적인 추론 NPU와 구분합니다. 홈페이지의 제조·샘플링 예정 표현은 날짜가 명확하지 않아 현재 완료 상태로 단정하지 않습니다. [S050]

필드	조사 기록
제품·기술	Rhea1
기업 상태	인접 분야 / HPC·AI 호스트 CPU
주요 고객 가설	HPC 시스템 공급사·연구용 슈퍼컴퓨터
측정할 조건	CPU 코드·메모리·가속기 조합
평가 지표	메모리 대역폭·실행 시간
시스템 경계	CPU·가속기·서버

탐색 태그

SiPearl, Rhea1, HPC 시스템 공급사·연구용 슈퍼컴퓨터

근거: S050. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

SiPearl | 시장성과 확인 과제

C34 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

메모리 대역폭이 큰 수치 계산과 AI를 조합하는 시스템에서 후보가 됩니다. 호스트 CPU·전후처리·일반 계산 수요를 평가하며 대형 추론 가속기와 동일한 제품 범주로 순위를 만들지 않습니다.

한계·도입 위험 | 분석·미확인

HPC 조달 일정과 시스템 통합에 의존할 수 있습니다. 넓은 메모리 대역폭의 이점이 고객 코드에서 실현되는지와 CPU 용 라이브러리 성숙도를 확인해야 합니다.

기업별 확인 질문

- 1. 메모리 집약적 HPC 코드에서 실측 byte-per-flop와 대역폭 이용률은 얼마인가?
- 2. 사용할 AI 가속기와 PCIe·드라이버·운영체제 호환성이 검증되었는가?
- 3. 공개 샘플링 일정 이후 현재 납품 가능한 구성은 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	동일 고객 문제를 해결하는 기존 시스템과 비교
고객 PoC의 고정 조건	CPU 코드·메모리·가속기 조합
결과 판정	메모리 대역폭·실행 시간을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SiPearl은(는) HPC·AI 호스트 CPU 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S050 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Enfabrica

C35 | 해외 | 연결·메모리 인프라

기업·사업 근거 | 공개 자료

AI 인프라용 SuperNIC인 ACF-S와 추론 오프로딩을 위한 Elastic AI Memory Fabric System을 소개합니다. 직접 AI 행렬 연산을 수행하는 NPU와 구분되는 연결 기술입니다. [S051]

핵심 기술 | 공개 자료

계산기·메모리·네트워크 사이의 연결과 탄력적 자원 구성이 핵심입니다. 외부 인용의 확장성 전망은 회사 제품의 고객 실측 결과와 다르므로 숫자 순위에 사용하지 않습니다. [S051]

필드	조사 기록
제품·기술	ACF-S / EMFASYS
기업 상태	인접 분야 / AI 네트워크 반도체
주요 고객 가설	AI 클러스터·서버·클라우드 네트워크 사업자
측정할 조건	토폴로지·트래픽·메모리 배치
평가 지표	유효 대역폭·p99 지연·복구
시스템 경계	스위치·링크·호스트·메모리

탐색 태그

Enfabrica, ACF-S / EMFASYS, AI 클러스터·서버·클라우드 네트워크 사업자

근거: S051. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Enfabrica | 시장성과 확인 과제

C35 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

가속기 자체보다 데이터 이동과 메모리 배치가 병목인 고객에서 검토할 수 있습니다. 더 높은 링크 이용률과 장애 대응이 서비스 가동률에 주는 영향을 구매 근거로 확인해야 합니다.

한계·도입 위험 | 분석·미확인

네트워크 교체는 운영 도구와 배선·토폴로지에 영향을 줍니다. 최대 대역폭이 실제 집단 통신이나 추론 지연의 개선으로 연결되는지 검증해야 합니다.

기업별 확인 질문

- 1. 실제 collective 통신과 KV cache 이동에서 병목을 얼마나 줄이는가?
- 2. 링크 장애·혼잡 시 p99 지연과 복구 시간이 어떻게 변하는가?
- 3. 기존 NIC·스위치 대비 소프트웨어와 운영 변경 범위는 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	Panmnesia
고객 PoC의 고정 조건	토폴로지·트래픽·메모리 배치
결과 판정	유효 대역폭·p99 지연·복구를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Enfabrica은(는) 연결·메모리 인프라 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S051 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Cerebras

C36 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

웨이퍼 규모 AI 계산 기술과 클라우드·온프레미스 서비스를 제공합니다. 현행 홈페이지는 CS-4 랙 시스템과 추론 API를 소개합니다. 공식 IR FAQ는 2026년 5월 14일 상장을 명시합니다. [S067] [S052]

핵심 기술 | 공개 자료

매우 큰 실리콘과 시스템의 공동 설계를 통해 AI 연산을 제공하는 접근입니다. 제품 세대별 학습·추론 기능을 나눠 기록합니다. 홈페이지도 비교 성능이 모델·구성·측정 날짜에 따라 달라질 수 있음을 명시합니다. [S052]

필드	조사 기록
제품·기술	Wafer-Scale Engine / CS-4
기업 상태	상장 비교 기업 / Nasdaq CBRS
주요 고객 가설	대형 AI 서비스·기업 추론·연구기관
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

Cerebras, Wafer-Scale Engine / CS-4, 대형 AI 서비스·기업 추론·연구기관

근거: S052 · S067. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Cerebras | 시장성과 확인 과제

C36 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

개별 사용자 응답 속도가 서비스 가치에 직접 영향을 주는 응용에 비교 대상으로 활용할 수 있습니다. 스타트업 투자 후보 목록에서는 상장 상태를 필터링하고 기술·고객 채택의 비교 기업으로 분류합니다.

한계·도입 위험 | 분석·미확인

시스템 크기와 공급 형태가 PCIe 카드와 다릅니다. 공개 고객 사례의 특정 성능을 모든 모델·언어·동시 요청 수준에 일반화할 수 없습니다.

기업별 확인 질문

- 1. 고객 모델의 자연 상한에서 총 처리량과 시스템 비용은 얼마인가?
- 2. API 사용과 전용 시스템 구매의 손익분기점은 어디인가?
- 3. 공개 실적의 성장과 단일 대형 고객 집중도를 구분할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Cerebras은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S052 · S067 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

SambaNova

C37 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

RDU 기반 추론 시스템과 소프트웨어·서비스를 제공합니다. 현행 홈페이지는 SambaRack SN50와 여러 모델을 운영하는 SambaStack을 소개합니다. [S053]

핵심 기술 | 공개 자료

dataflow 처리와 3계층 메모리 구조를 강조합니다. 모델·프롬프트를 캐시하고 다양한 모델을 전환하는 운영 방식이 특징입니다. 사이트의 비용 절감 배수와 회수기간은 해당 사업 가정의 주장입니다. [S053]

필드	조사 기록
제품·기술	RDU / SambaRack SN50
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	기업·주권형 AI·여러 모델을 운영하는 클라우드
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

SambaNova, RDU / SambaRack SN50, 기업·주권형 AI·여러 모델을 운영하는 클라우드

근거: S053. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

SambaNova | 시장성과 확인 과제

C37 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

모델을 자주 바꾸는 에이전트 서비스와 큰 모델을 사내에서 운영하려는 고객을 탐색할 수 있습니다. 메모리 계층이 모델 전환 시간을 줄인다면 낮은 빈도의 여러 모델을 묶는 운영에서 편익이 생길 수 있습니다.

한계·도입 위험 | 분석·미확인

랙 사양·모델 캐시·호스트·실제 전력의 경계를 확인해야 합니다. 예상 매출에 기반한 투자 회수기간을 모든 고객의 비용 절감으로 답하면 안 됩니다.

기업별 확인 질문

- 모델 전환 시 cold start와 cache miss 지연은 얼마인가?
- SN40과 SN50의 소프트웨어·모델 지원 차이는 무엇인가?
- 회수기간 계산에 판매율·가격·가동률·이전 비용이 반영되었는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

SambaNova은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S053 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Groq

C38 | 해외 | AI 추론 클라우드

기업·사업 근거 | 공개 자료

2026년 6월 22일 회사는 추론 클라우드 확장을 위한 6억 5,000만 달러 조달을 발표했습니다. 2025년 12월 NVIDIA와 비독점 기술 라이선스 계약을 맺은 뒤 클라우드 사업에 집중한다고 설명합니다. [S054]

핵심 기술 | 공개 자료

현재 사업 설명은 LPU 운영 경험과 NVIDIA LPX 시스템을 포함하는 추론 인프라에 초점을 둡니다. 과거의 독립 칩 개발사 설명만으로 현재 수익 모델을 판단하지 않습니다. 라이선스 계약을 회사 전체 인수로 기록하지 않습니다. [S070] [S054]

필드	조사 기록
제품·기술	LPU 계보 / 추론 클라우드
기업 상태	사업 전환 사례 / 추론 클라우드 중심
주요 고객 가설	빠른 모델 API가 필요한 AI 앱·추론 서비스 고객
측정할 조건	모델·지역·요청 길이·요금
평가 지표	유효 토큰·SLA·유상 유지율
시스템 경계	서버·전력·운영·서비스

탐색 태그

Groq, LPU 계보 / 추론 클라우드, 빠른 모델 API가 필요한 AI 앱·추론 서비스 고객

근거: S054 · S070. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Groq | 시장성과 확인 과제

C38 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

고객이 하드웨어를 직접 구매하기보다 빠른 API를 사용하려는 수요에 연결됩니다. 칩 판매의 매출총이익보다 서버 가동률·토큰 판매·전력·모델 제공 범위가 사업 분석에 중요해집니다.

한계·도입 위험 | 분석·미확인

API 가격과 모델 목록은 자주 바뀌므로 본 문서는 고정 가격표를 제공하지 않습니다. 개발자 수·처리 토큰 수는 회사 주장이고 유상 고객 수·순매출과 같지 않습니다.

기업별 확인 질문

- 1. 유상 요청 비율과 고객별 토큰 사용 지속성은 어떠한가?
- 2. 외부 하드웨어 공급과 소프트웨어 로드맵에 대한 의존도는 얼마인가?
- 3. 지연 SLA·지역 가용성·지원 모델을 실제 고객 요청으로 검증했는가?

비교·검증 축	실행할 확인
적합한 비교군	동일 고객 문제를 해결하는 기존 시스템과 비교
고객 PoC의 고정 조건	모델·지역·요청 길이·요금
결과 판정	유효 토큰·SLA·유상 유지율을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Groq은(는) AI 추론 클라우드 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S054 · S070 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Graphcore

C39 | 해외 | 데이터센터 AI 계산

기업·사업 근거 | 공개 자료

2024년 공식 발표에 따르면 SoftBank에 인수되어 완전 자회사가 되었고 Graphcore 이름으로 운영을 계속합니다. 발표 당시 본사는 Bristol로 유지된다고 설명했습니다. [S055]

핵심 기술 | 공개 자료

AI 실리콘·하드웨어·소프트웨어 전체를 개발하는 기업입니다. 과거 IPU 기술 계보는 비교 맥락이며, 이번 확인 자료만으로 차세대 제품의 세부 성능이나 공급 일정을 확정하지 않습니다. [S055]

필드	조사 기록
제품·기술	AI compute / IPU 계보
기업 상태	인수 완료 비교 기업 / SoftBank 자회사
주요 고객 가설	AI 인프라 기술 비교·대규모 시스템 파트너
측정할 조건	모델·정확도·문맥·동시성
평가 지표	첫 토큰 지연·토큰 간 지연·처리량
시스템 경계	카드·호스트·통신·냉각

탐색 태그

Graphcore, AI compute / IPU 계보, AI 인프라 기술 비교·대규모 시스템 파트너

근거: S055. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Graphcore | 시장성과 확인 과제

C39 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

독립 스타트업의 확장과 대형 자본·생태계 결합을 비교하는 사례입니다. 투자 탐색에서 독립 비상장 기업 조건을 적용하면 제외하고 인수·회수·기술 통합 사례로 활용합니다.

한계·도입 위험 | 분석·미확인

인수 완료는 기술의 모든 상업적 문제가 해결되었다는 뜻이 아닙니다. 모회사 내 제품 우선순위와 외부 고객 공급 정책을 확인해야 합니다.

기업별 확인 질문

- 1. 현재 외부 고객에게 공급하는 제품과 장기 지원 정책은 무엇인가?
- 2. 기존 IPU 고객의 모델·도구를 차세대로 이전할 수 있는가?
- 3. 모회사 내 수요와 외부 유상 고객의 비중을 구분할 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	FuriosaAI, Rebellions, d-Matrix
고객 PoC의 고정 조건	모델·정확도·문맥·동시성
결과 판정	첫 토큰 지연·토큰 간 지연·처리량을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Graphcore은(는) 데이터센터 AI 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S055 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Blaize

C40 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

Graph Streaming Processor와 Pathfinder·Xplorer 엣지 플랫폼, AI 소프트웨어를 제공합니다. 공식 홈페이지의 실적 발표 링크는 Nasdaq BZAI 상장 상태를 명시합니다. [S056]

핵심 기술 | 공개 자료

그래프 구조의 계산과 프로그래머블 데이터 흐름을 강조합니다. AI Studio와 응용 단위 서비스를 소개하며 하드웨어 부터 배포 도구까지 제공하는 전략입니다. [S056]

필드	조사 기록
제품·기술	GSP / Pathfinder / Xplorer
기업 상태	상장 비교 기업 / Nasdaq BZAI
주요 고객 가설	산업용 엣지·시스템 통합사·서비스 사업자
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

Blaize, GSP / Pathfinder / Xplorer, 산업용 엣지·시스템 통합사·서비스 사업자

근거: S056. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Blaize | 시장성과 확인 과제

C40 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

하드웨어 자체의 성능보다 배포·운영 시간을 줄이는 솔루션을 원하는 고객에게 비교 후보입니다. 상장 기업이므로 사업성 판단에 공개 실적과 현금흐름을 추가 결합할 수 있습니다.

한계·도입 위험 | 분석·미확인

코드 없는 도구가 모든 모델과 현장 통합을 자동 처리한다고 가정하지 않습니다. 기술 제휴와 실적 계약, 제품과 서비스 매출의 구분이 필요합니다.

기업별 확인 질문

- 1. 고객의 기존 모델을 AI Studio에서 배포하는 실제 시간은 얼마인가?
- 2. 프로젝트별 개발 용역과 반복 가능한 제품 매출은 어떻게 나뉘는가?
- 3. 공개 재무 실적과 발표된 수주·파트너십이 일치하는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Blaize은(는) 엣지 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S056 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

BrainChip

C41 | 해외 | 뉴로모픽·희소 계산

기업·사업 근거 | 공개 자료

Akida 뉴로모픽 IP, 칩, 모델 및 개발 플랫폼을 제공합니다. 음성·영상·센서 처리를 대상으로 하며 현행 사이트는 GenAI용 FPGA 개발 경로도 소개합니다. [S057] 2026년 6월 30일 공식 발표는 ASX: BRN 상장사임을 명시하고 AKD1500의 상용 공급 및 초기 생산 출하를 알립니다. [S088]

핵심 기술 | 공개 자료

디지털 뉴로모픽 신경망 처리와 IP 통합 접근입니다. FPGA 검증 플랫폼은 양산 ASIC 출하와 구분합니다. GenAI 지원을 기존 모든 Akida 칩의 기능으로 확장하지 않습니다. [S057]

필드	조사 기록
제품·기술	Akida / Akida GenAI
기업 상태	상장 비교 기업 / ASX BRN
주요 고객 가설	초저전력 SoC·센서·임베디드 설계사
측정할 조건	이벤트 표현·희소성·목표 품질
평가 지표	사건별 지연·전체 에너지
시스템 경계	입력 변환·칩·후처리

탐색 태그

BrainChip, Akida / Akida GenAI, 초저전력 SoC·센서·임베디드 설계사

근거: S057 · S088. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

BrainChip | 시장성과 확인 과제

C41 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

칩 단품과 IP 라이선스 중 고객이 선택할 수 있는 경로가 있습니다. 센서 이벤트의 시간적 패턴을 활용하는 문제에서 검토허지 모델의 표현·학습·정확도 제약을 함께 평가합니다.

한계·도입 위험 | 분석·미확인

제품 세대·IP 구성·FPGA 시연을 구분합니다. AKD1500의 초기 출하와 산업·군용 적격성 검증 완료는 다르며, 해당 발표에서 적격성 검증은 진행 중입니다.

기업별 확인 질문

- 1. 고객이 도입할 Akida 세대와 모델 변환 경로는 정확히 무엇인가?
- 2. on-device 학습·추론 기능의 적용 범위가 해당 SKU에 포함되는가?
- 3. IP 라이선스 이후 고객 테이프아웃과 로열티 발생까지의 기간은 얼마인가?

비교·검증 축	실행할 확인
적합한 비교군	Innatera, SynSense, SpiNNcloud
고객 PoC의 고정 조건	이벤트 표현·희소성·목표 품질
결과 판정	사건별 지연·전체 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

BrainChip은(는) 뉴로모픽·희소 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S057 · S088 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Kinara

C42 | 해외 | 엣지 AI·영상 계산

기업·사업 근거 | 공개 자료

NXP는 2025년 10월 27일 Kinara 인수 완료를 발표했습니다. 공식 소개는 Ara-1 6 eTOPS와 Ara240 40 eTOPS를 제시하며 생성형·영상 AI용 discrete NPU로 설명합니다. [S058]

핵심 기술 | 공개 자료

프로그래머블 RISC-V 기반 dataflow와 MAC 연산기를 결합합니다. eTOPS의 정의·조건을 확인하기 전 일반 TOPS와 같은 값으로 순위화하지 않습니다. NXP 포트폴리오 내 제품 공급 경로를 확인해야 합니다. [S058]

필드	조사 기록
제품·기술	Ara-1 / Ara240
기업 상태	인수 완료 비교 기업 / NXP
주요 고객 가설	스마트 카메라·산업 장비·임베디드 시스템 OEM
측정할 조건	센서 수·해상도·모델·온도
평가 지표	정확도·프레임 지연·지속 성능
시스템 경계	가속기·호스트·센서·방열

탐색 태그

Kinara, Ara-1 / Ara240, 스마트 카메라·산업 장비·임베디드 시스템 OEM

근거: S058. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Kinara | 시장성과 확인 과제

C42 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

큰 반도체 회사의 영업·지원 경로로 오히려 NPU가 확산되는 사례입니다. 독립 스타트업 후보에서 제외하되 유사 기업의 인수 수요와 고객 통합 전략을 이해하는 비교 자료가 됩니다.

한계·도입 위험 | 분석·미확인

인수 이전 이름과 이후 제품명이 달라질 수 있습니다. NXP의 기존 SoC와 신규 NPU의 결합이 실제 BOM·소프트웨어 비용을 줄이는지 검증해야 합니다.

기업별 확인 질문

- 1. 현재 Ara 제품의 주문·지원·장기 공급 책임은 어느 조직에 있는가?
- 2. eTOPS 수치와 고객 모델의 정확도·실제 처리량의 관계는 무엇인가?
- 3. NXP 호스트와 결합했을 때 독립 모듈 대비 통합 비용이 줄어드는가?

비교·검증 축	실행할 확인
적합한 비교군	Mobilint, DEEPX, Hailo
고객 PoC의 고정 조건	센서 수·해상도·모델·온도
결과 판정	정확도·프레임 지연·지속 성능을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Kinara은(는) 오히려 AI·영상 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S058 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Lightmatter

C43 | 해외 | 광연결 인프라

기업·사업 근거 | 공개 자료

현행 제품은 Passage 광 인터커넥트와 Guide 광원을 중심으로 AI 슈퍼컴퓨터의 연결을 확장합니다. 직접적인 AI 행렬 연산 칩과 구별해 인접 분야로 분류합니다. [S059]

핵심 기술 | 공개 자료

CPO와 3D 광 인터포저, 광원 집적을 소개합니다. 대역폭·에너지/bit는 링크 성능 지표이며 토큰/초나 FLOPS와 같은 계산 성능 지표가 아닙니다. 여러 레퍼런스 플랫폼의 수치를 혼합하지 않습니다. [S059]

필드	조사 기록
제품·기술	Passage / Guide
기업 상태	인접 분야 / 광연결 반도체
주요 고객 가설	대규모 AI 클러스터·XPU·패키징·네트워크 고객
측정할 조건	링크 거리·속도·패키지·열
평가 지표	bit/s·pJ/bit·오류율
시스템 경계	광원·송수신·패키지·제어

탐색 태그

Lightmatter, Passage / Guide, 대규모 AI 클러스터·XPU·패키징·네트워크 고객

근거: S059. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Lightmatter | 시장성과 확인 과제

C43 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

칩 수가 늘어 전기 연결의 거리·밀도·전력이 문제가 되는 환경에서 후보입니다. 연산기와 공존하는 보완 기술로서 가속기 제조사·하이퍼스케일러와의 설계 채택이 중요합니다.

한계·도입 위험 | 분석·미확인

광원·패키징·열 안정성·수리 가능성과 실제 시스템 통합 비용이 관건입니다. 데모 대역폭이 모든 네트워크 트래픽의 유효 처리량을 보장하지 않습니다.

기업별 확인 질문

- 1. 광원 전력과 보정·패키징까지 포함한 링크 에너지/bit는 얼마인가?
- 2. 패키지 수율·검사·재작업 비용을 양산 규모에서 확인했는가?
- 3. 고객 설계 채택은 평가 단계인가 확정 양산 프로그램인가?

비교·검증 축	실행할 확인
적합한 비교군	Celestial AI
고객 PoC의 고정 조건	링크 거리·속도·패키지·열
결과 판정	bit/s·pJ/bit·오류율을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Lightmatter은(는) 광연결 인프라 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S059 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Lightelligence

C44 | 해외 | 광전자 계산

기업·사업 근거 | 공개 자료

광전자 혼합 계산과 광연결 제품을 함께 제공합니다. PACE 2는 2025년 발표한 광전자 가속 카드이며 Gazelle은 광 행렬 연산 평가 보드, Photowave는 분리형 메모리용 광연결 제품입니다. [S060] 공식 회사 연혁은 2026년 4월 28일 홍콩거래소 상장과 종목코드 01879.HK를 명시합니다. [S087]

핵심 기술 | 공개 자료

광연산과 oNET 연결을 나눠 평가해야 합니다. 공개 소개는 Gazelle의 8×2 기본 광행렬 계산과 Photowave의 PCIe·CXL 호환 범위를 설명합니다. 연구 평가 보드의 기능을 범용 LLM 카드의 성능으로 확대하지 않습니다. [S060]

필드	조사 기록
제품·기술	PACE 2 / Photowave
기업 상태	상장 비교 기업 / HKEX 01879
주요 고객 가설	광연산 연구·AI 메모리·데이터센터 연결 고객
측정할 조건	지원 함수·정밀도·입출력 변환
평가 지표	연산 품질·시스템 에너지
시스템 경계	광원·광학부·변환·메모리

탐색 태그

Lightelligence, PACE 2 / Photowave, 광연산 연구·AI 메모리·데이터센터 연결 고객

근거: S060 · S087. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Lightelligence | 시장성과 확인 과제

C44 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

계산과 연결을 각각 다른 고객 예산에 판매할 수 있는 구조입니다. 고객이 광학 기술을 평가하는 목적이 연산 에너지 절감인지 메모리 연결 확장인지 먼저 분리해야 합니다.

한계·도입 위험 | 분석·미확인

카드·평가보드·연결 제품을 한 제품으로 합치면 검색 결과가 왜곡됩니다. 상장 이후의 매출 구성과 고객 집중도는 재무 공시로 별도 확인해야 합니다.

기업별 확인 질문

- 1. PACE의 실제 지원 연산·정밀도·컴파일 도구 범위는 무엇인가?
- 2. Photowave의 실사용 지연·호환성과 CXL 메모리 관리가 검증되었는가?
- 3. 평가 장비 판매와 양산 부품 공급의 매출 비중은 어떻게 다른가?

비교·검증 축	실행할 확인
적합한 비교군	Lumai, Q.ANT
고객 PoC의 고정 조건	지원 함수·정밀도·입출력 변환
결과 판정	연산 품질·시스템 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Lightelligence은(는) 광전자 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S060 · S087 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Celestial AI

C45 | 해외 | 광연결 인프라

기업·사업 근거 | 공개 자료

Marvell은 2026년 2월 2일 Celestial AI 인수 완료를 발표했습니다. Photonic Fabric은 큰 AI 시스템의 scale-up 광연결 기술이며 Marvell Data Center Group에 통합된다고 설명합니다. [S061]

핵심 기술 | 공개 자료

높은 대역폭·낮은 지연의 광연결을 계산 인프라에 통합하는 기술입니다. 회사 발표의 미래 매출 기여 예상은 실적이 아니며, 광연결을 신경망 연산기라고 분류하지 않습니다. [S061]

필드	조사 기록
제품·기술	Photonic Fabric
기업 상태	인수 완료 비교 기업 / Marvell
주요 고객 가설	AI XPU·scale-up 네트워크·하이퍼스케일 고객
측정할 조건	링크 거리·속도·패키지·열
평가 지표	bit/s·pJ/bit·오류율
시스템 경계	광원·송수신·패키지·제어

탐색 태그

Celestial AI, Photonic Fabric, AI XPU·scale-up 네트워크·하이퍼스케일 고객

근거: S061. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Celestial AI | 시장성과 확인 과제

C45 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

AI 연산기 주변의 연결 병목 해결 기술이 전략적 인수 대상이 되는 사례입니다. 독립 투자 후보보다 기술 회수 경로와 인프라 기업의 포트폴리오 확장 분석에 사용합니다.

한계·도입 위험 | 분석·미확인

매출 기여 시작 시점·run rate는 구매자의 전망입니다. 기술 통합·고객 설계·양산 일정의 이행과 실제 매출 발생을 추적해야 합니다.

기업별 확인 질문

- 1. 광연결 제품의 고객 설계 고정 시점과 양산 일정은 무엇인가?
- 2. 인수 후 기존 계약과 기술 지원은 어떻게 이어지는가?
- 3. 예상 연환산 매출과 해당 회계기간 인식 매출을 구분했는가?

비교·검증 축	실행할 확인
적합한 비교군	Lightmatter
고객 PoC의 고정 조건	링크 거리·속도·패키지·열
결과 판정	bit/s·pJ/bit·오류율을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Celestial AI은(는) 광연결 인프라 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S061 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Lumai

C46 | 해외 | 광전자 계산

기업·사업 근거 | 공개 자료

3D 광학 구성요소를 이용하는 추론 가속기를 개발합니다. 회사는 넓은 인터페이스, 데이터 변환 오버헤드의 분산, 광학 제약을 반영한 양자화를 소개합니다. [S062]

핵심 기술 | 공개 자료

빛을 활용하는 계산 경로와 전자 회로·메모리를 결합해야 하는 구조입니다. 공개 사이트의 50배 성능은 로드맵 표현이며 실제 출하 시스템의 측정치로 사용하지 않습니다. [S062]

필드	조사 기록
제품·기술	3D optical compute
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	광연산 평가·대규모 추론 인프라 고객
측정할 조건	지원 함수·정밀도·입출력 변환
평가 지표	연산 품질·시스템 에너지
시스템 경계	광원·광학부·변환·메모리

탐색 태그

Lumai, 3D optical compute, 광연산 평가·대규모 추론 인프라 고객

근거: S062. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Lumai | 시장성과 확인 과제

C46 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

연산 집약적인 단계에서 병렬 광학 연산의 편익을 검토할 수 있습니다. 메모리에서 광학 계산부로 데이터를 공급하고 다시 디지털로 가져오는 비용까지 절감해야 고객 가치가 생깁니다.

한계·도입 위험 | 분석·미확인

광학 정렬·변환 정밀도·환경 안정성과 시스템 제조성이 주요 확인점입니다. 광학 연산부의 효율만으로 전체 LLM 서비스 비용을 추정하면 안 됩니다.

기업별 확인 질문

- 1. DAC·ADC·광원·호스트를 포함해 end-to-end 에너지를 측정했는가?
- 2. 광학 제약을 반영한 양자화 뒤 모델 품질은 유지되는가?
- 3. 현재 고객 평가 가능한 하드웨어와 로드맵 사이의 차이는 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	Lightelligence, Q.ANT
고객 PoC의 고정 조건	지원 함수·정밀도·입출력 변환
결과 판정	연산 품질·시스템 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Lumai은(는) 광전자 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S062 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Q.ANT

C47 | 해외 | 광전자 계산

기업·사업 근거 | 공개 자료

AI·HPC용 광연산 플랫폼을 제공합니다. 현행 홈페이지는 LRZ·Jülich 배치와 2세대 광 프로세서의 비선형 함수 처리량 8 GOPS를 소개합니다. [S063]

핵심 기술 | 공개 자료

광학 영역에서 비선형 연산을 직접 수행하는 접근을 강조합니다. Native Processing Unit의 약어 NPU를 일반 Neural Processing Unit과 혼동하지 않습니다. 8 GOPS는 지정 연산의 지속 처리량으로 범용 AI TOPS와 다릅니다. [S063]

필드	조사 기록
제품·기술	Native Processing Server / NPU Gen 2
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	HPC 연구기관·과학 계산·광연산 개발 고객
측정할 조건	지원 함수·정밀도·입출력 변환
평가 지표	연산 품질·시스템 에너지
시스템 경계	광원·광학부·변환·메모리

탐색 태그

Q.ANT, Native Processing Server / NPU Gen 2, HPC 연구기관·과학 계산·광연산 개발 고객

근거: S063. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

Q.ANT | 시장성과 확인 과제

C47 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

광학 소자의 특성이 잘 맞는 수학 연산과 작은 모델의 표현력을 활용하는 문제를 먼저 탐색할 수 있습니다. 일반 LLM 전체를 즉시 대체한다는 주장보다 특정 응용의 검증 경로가 중요합니다.

한계·도입 위험 | 분석·미확인

소프트웨어·하드웨어 접근 가능 시점과 지원 함수 범위를 확인해야 합니다. 장래 효율 배수와 현행 지속 처리량은 서로 다른 지표입니다.

기업별 확인 질문

- 지원되는 비선형 함수·정밀도·입력 범위가 고객 문제에 맞는가?
- 시뮬레이션과 실제 광 프로세서 결과의 차이를 측정했는가?
- 범용 CPU·GPU의 최적화된 같은 연산과 시스템 비용을 비교했는가?

비교·검증 축	실행할 확인
적합한 비교군	Lightelligence, Lumai
고객 PoC의 고정 조건	지원 함수·정밀도·입출력 변환
결과 판정	연산 품질·시스템 에너지를 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Q.ANT은(는) 광전자 계산 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S063 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Biren Technology

C48 | 해외 | AI · HPC GPU

기업 · 사업 근거 | 공개 자료

중국의 GPU 기반 AI 계산 솔루션 기업입니다. 공식 회사 소개는 2019년 설립, 2026년 1월 2일 홍콩거래소 상장과 종목코드 06082.HK를 명시합니다. [S064]

핵심 기술 | 공개 자료

자체 GPU 구조와 칩렛, 소프트웨어 · 하드웨어 공동 개발을 설명합니다. 현재 제품군의 정밀 사양과 독립 비교 결과를 이번 자료만으로 확정하지 않으며 과거 BR100 사양을 현행 전 제품에 적용하지 않습니다. [S064]

필드	조사 기록
제품 · 기술	GPU / chiplet
기업 상태	상장 비교 기업 / HKEX 06082
주요 고객 가설	중국 AI 데이터센터 · 통신 · 기업 인프라
측정할 조건	프레임워크 · 정밀도 · 분산 규모
평가 지표	학습 수렴 · 추론 SLA · 안정성
시스템 경계	GPU · 호스트 · 네트워크

탐색 태그

Biren Technology, GPU / chiplet, 중국 AI 데이터센터 · 통신 · 기업 인프라

근거: S064. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용 · 시장 분석은 별도 가설입니다.

Biren Technology | 시장성과 확인 과제

C48 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

지역 내 계산 공급망과 소프트웨어 생태계 수요를 파악하는 상장 비교 기업입니다. 목표 고객의 실제 모델 호환성과 클러스터 안정성이 정책·지역 수요만큼 중요합니다.

한계·도입 위험 | 분석·미확인

시장 접근·공급·수출입 조건은 개별 거래 시점에 확인해야 합니다. 본 보고서는 규제 적용 여부나 투자 가능성을 법적으로 판정하지 않습니다.

기업별 확인 질문

- 1. 지원하는 프레임워크와 최신 모델의 전환 비용은 얼마인가?
- 2. 클러스터 장시간 학습·추론의 오류율과 복구 지표가 있는가?
- 3. 공개 매출 성장과 특정 고객·프로젝트 집중도를 분리해 볼 수 있는가?

비교·검증 축	실행할 확인
적합한 비교군	Moore Threads
고객 PoC의 고정 조건	프레임워크·정밀도·분산 규모
결과 판정	학습 수렴·추론 SLA·안정성을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Biren Technology은(는) AI·HPC GPU 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S064 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

Moore Threads

C49 | 해외 | AI · HPC GPU

기업 · 사업 근거 | 공개 자료

MTT S5000은 PH100 기반의 학습 · 추론 · HPC용 GPU로 소개됩니다. 제품 페이지는 FP8부터 FP64까지와 MUSA 소프트웨어 플랫폼을 제시합니다. [S065] 상하이거래소 공고에 따른 STAR Market 상장일은 2025년 12월 5일이며 종목코드는 688795입니다. [S086]

핵심 기술 | 공개 자료

PyTorch · Megatron-LM · vLLM · SGLang 지원 및 대형 클러스터 확장을 강조합니다. 회사가 제시하는 이전 편의성 · 비교 성능은 고객 코드 · 버전 · 통신 환경에서 확인할 주장입니다. [S065]

필드	조사 기록
제품 · 기술	MTT S5000 / MUSA
기업 상태	상장 비교 기업 / SSE STAR 688795
주요 고객 가설	중국 AI 학습 · 추론 · HPC 클러스터 고객
측정할 조건	프레임워크 · 정밀도 · 분산 규모
평가 지표	학습 수렴 · 추론 SLA · 안정성
시스템 경계	GPU · 호스트 · 네트워크

탐색 태그

Moore Threads, MTT S5000 / MUSA, 중국 AI 학습 · 추론 · HPC 클러스터 고객

근거: S065 · S086 · S500. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용 · 시장 분석은 별도 가설입니다.

Moore Threads | 시장성과 확인 과제

C49 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

기존 GPU 코드를 지역 내 대체 하드웨어에서 운영하려는 고객의 비교 대상입니다. 칩 성능 외에 라이브러리 커버리지·운영 안정성·기존 코드 수정량이 도입 비용을 결정합니다.

한계·도입 위험 | 분석·미확인

제품 페이지의 대규모 실험을 작은 장비나 다른 모델의 성능으로 일반화하지 않습니다. 실제 제품 공급과 매출·고객 집중도는 최신 공시 및 고객 증거로 확인해야 합니다.

기업별 확인 질문

- 1. 고객 CUDA 코드의 미지원 기능과 변환 후 수치 차이는 무엇인가?
- 2. 실제 네트워크에서 분산 학습의 통신 효율과 장기 안정성이 유지되는가?
- 3. 모델별 kernel·compiler 업데이트를 누가 얼마나 빠르게 제공하는가?

비교·검증 축	실행할 확인
적합한 비교군	Biren Technology
고객 PoC의 고정 조건	프레임워크·정밀도·분산 규모
결과 판정	학습 수렴·추론 SLA·안정성을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

Moore Threads은(는) AI·HPC GPU 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S065 · S086 · S500 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

REEXEN

C50 | 해외 | 메모리·연산 결합

기업·사업 근거 | 공개 자료

중국 Shenzhen에서 설립된 메모리·계산 결합 칩 기업입니다. SRAM 기반 CIM, Attention 가속, AI 보드·서버와 저장장치 기술을 소개합니다. [S066]

핵심 기술 | 공개 자료

ADA300은 SRAM CIM 위에 NAND 또는 DRAM을 수직 결합하는 방향을 제시합니다. TSV·hybrid bonding으로 가중치·Attention 데이터·KV cache를 계산 가까이 두는 구조를 설명합니다. [S066]

필드	조사 기록
제품·기술	ADA300 / SRAM CIM
기업 상태	공개 사업 확인 / 최신 투자 단계 미확인
주요 고객 가설	엣지 추론·AI 메모리·큰 모델 시스템 개발사
측정할 조건	소자·정밀도·온도·교정
평가 지표	품질 유지·에너지·제조성
시스템 경계	변환 회로·연산 배열·호스트

탐색 태그

REEXEN, ADA300 / SRAM CIM, 엣지 추론·AI 메모리·큰 모델 시스템 개발사

근거: S066. 조회 2026-09-29. 제품 페이지의 공개 주장과 독립 실측은 구분합니다. 다음 페이지의 적용·시장 분석은 별도 가설입니다.

REEXEN | 시장성과 확인 과제

C50 | 분석·검증 설계 | 앞 페이지의 공개 근거와 연결

고객 문제와 수요 | 분석

메모리 용량과 대역폭을 함께 확보해야 하는 추론 환경이 탐색 대상입니다. NAND와 DRAM 구성은 지연·비용·갱신 특성이 다르므로 고객 워크로드에 맞는 경로를 구분해야 합니다.

한계·도입 위험 | 분석·미확인

공개 아키텍처를 모든 제품의 양산 실적으로 취급하지 않습니다. 적층 제조성·열·대역폭과 실제 메모리 계층의 관리 비용을 확인해야 합니다.

기업별 확인 질문

- 1. NAND와 DRAM 적층 구성 각각에서 실측 추론 결과를 제시하는가?
- 2. 긴 문맥과 KV cache 갱신 시 대역폭·내구성·지연 한계는 무엇인가?
- 3. 공개 구조 중 고객 평가·양산·로드맵에 해당하는 항목은 무엇인가?

비교·검증 축	실행할 확인
적합한 비교군	Mythic, SEMRON
고객 PoC의 고정 조건	소자·정밀도·온도·교정
결과 판정	품질 유지·에너지·제조성을 같은 품질 조건에서 측정
상업 증거	샘플·유상 PoC·검수·반복 주문을 구분

RAG 답변의 경계

REEXEN은(는) 메모리·연산 결합 질의에 연결할 수 있습니다. 위 비교군은 같은 범주의 검토 대상이며 동등한 제품이 나 성능 순위가 아닙니다. 매출·마진·점유율 또는 실측 결과가 없으면 값을 만들어 평가 점수를 채우지 않습니다.

근거 연결: S066 | 투자 판단에는 현재 법인·계약·재무·제품 가용성의 추가 확인이 필요합니다.

학습용 칩과 추론용 칩을 구분하기

T01 | 기술 요약 에이전트

근거와 범위

Esperanto와 Moore Threads는 AI 외 HPC 또는 학습을 함께 설명하고, Fractile은 frontier 모델 추론을 중심에 둡니다. 같은 AI 반도체라는 이유만으로 구매 목적이 같지는 않습니다. [S048, S065, S044]

해석

[분석] 학습은 순전파·역전파·옵티마이저 상태의 갱신을 요구합니다. 추론은 이미 학습된 모델을 실행하지만 요청 길이와 동시성에 따라 병목이 달라집니다. 학습·추론 통합 장비는 활용률을 높일 가능성이 있고 특화 장비는 지정 부하의 효율을 높일 가능성이 있습니다. 어느 쪽이 유리한지는 운영 계획으로 판단합니다.

축	확인할 입력	평가 의미
학습	모델·데이터·옵티마이저 상태	수렴 품질·학습 완료 시간
미세조정	전체 또는 일부 가중치 갱신	지원 방식·메모리·정확도
배치 추론	다수 입력을 모아 처리	처리량·유효 결과당 비용
실시간 추론	개별 요청에 빠르게 응답	p95/p99 지연·동시성
혼합 운영	학습과 추론 자원 공유	스케줄링·간섭·이용률

평가·검색에 적용

학습 기능을 요구하지 않는 고객에게 학습 peak 수치를 강조하지 않습니다. 반대로 추론만 가능한 장비를 범용 연구용 학습 서버로 추천하지 않습니다. 탐색 조건에 workload_type을 저장하면 부적합 후보를 먼저 제거할 수 있습니다.

연결할 질의

“학습도 가능한 AI 칩”, “추론 전용 ASIC”, “학습·추론 혼합 운영”

Prefill과 decode의 병목

T02 | 기술 요약 에이전트

근거와 범위

d-Matrix는 GPU와 Corsair를 함께 사용하는 분리 추론을 소개합니다. 이는 서로 다른 단계의 요구에 다른 하드웨어를 배치하는 회사의 접근입니다. [S014]

해석

[분석] Prefill은 입력 문맥의 표현을 계산하고 decode는 생성 토큰을 순차적으로 늘립니다. 긴 입력, 큰 배치, 많은 동시 요청이 있을 때 각각의 계산·메모리 요구가 달라집니다. “prefill은 항상 연산, decode는 항상 메모리”처럼 절대 규칙으로 쓰기보다 실제 프로파일링으로 확인합니다.

축	확인할 입력	평가 의미
입력 문맥 증가	입력 토큰·cache 상태	첫 토큰 지연
출력 길이 증가	생성 토큰·종료 조건	전체 응답 시간
동시성 증가	요청 수·스케줄러	처리량과 대기열
분리 추론	KV 전송·두 풀의 크기	전송·재균형 비용
혼합 장비	GPU·ASIC 비율	낮은 이용률의 비용

평가·검색에 적용

두 장비를 나누면 각 단계의 효율은 좋아져도 전송·대기 비용이 커질 수 있습니다. 테스트는 단일 요청 속도와 함께 서비스 전체 처리량을 측정하고, 트래픽이 줄었을 때 한쪽 장비가 유휴 상태로 남는지도 확인해야 합니다.

연결할 질의

“decode 가속기”, “긴 프롬프트 추론”, “prefill decode 분리”

HBM · SRAM · LPDDR의 역할

T03 | 기술 요약 에이전트

근거와 범위

RNGD는 HBM3, REBEL100은 HBM3E를 공개합니다. d-Matrix와 MatX는 SRAM의 활용을 강조하고 엣지 제품은 LPDDR를 사용하는 사례가 있습니다. [S001, S004, S014, S045, S008]

해석

[분석] 메모리는 용량·대역폭·지연·전력·원가가 함께 결정하는 설계 요소입니다. SRAM은 계산 가까이에 둘 수 있지만 같은 면적에서 큰 용량을 만들기 어렵습니다. HBM의 대역폭과 LPDDR의 시스템 구성은 다른 제약에 대응합니다. 메모리 종류만으로 우열을 정하지 않습니다.

축	확인할 입력	평가 의미
가중치	모델 크기·비트 폭	상주 가능 용량
KV cache	문맥·동시성·구조	운영 중 증가량
활성값	배치·연산 순서	피크 메모리
메모리 이동	연산 강도·재사용	대역폭 병목
다중 칩	분할·통신 구조	추가 링크 비용

평가·검색에 적용

“모델이 들어간다”와 “지연 목표를 만족한다”는 별개입니다. 가중치만 계산한 최소 용량에는 KV cache와 런타임 작업 공간이 빠집니다. 제품 비교표에는 메모리 종류, 용량, 대역폭, 구성 경계를 각각 기록합니다.

연결할 질의

“HBM 기반 추론”, “SRAM LLM 가속기”, “메모리 용량이 큰 AI 칩”

양자화: 숫자 형식보다 모델 품질

T04 | 기술 요약 에이전트

근거와 범위

SmoothQuant는 학습 후 W8A8 양자화를, AWQ는 activation 정보를 이용한 가중치 양자화를 다룹니다. 방법과 대상이 달라 동일한 “INT8/INT4 지원”이라는 말로 묶기 어렵습니다. [S072, S073]

해석

[분석] 양자화는 가중치·활성값·KV cache의 어느 부분을 줄이는지 구분해야 합니다. 저장 형식과 실제 연산 형식도 다를 수 있습니다. 하드웨어가 해당 데이터 형식을 지원해도 정확도, kernel 지원, 변환 비용이 맞아야 서비스에 쓸 수 있습니다.

측	확인할 입력	평가 의미
가중치 정밀도	저장 크기·대역폭	원본 대비 품질
활성값 정밀도	연산 경로·outlier	레이어별 오차
KV 정밀도	문맥 메모리	장문 성능
교정 데이터	분포·언어·도메인	현장 일반화
혼합 정밀도	민감 연산의 유지	속도·정확도 균형

평가·검색에 적용

제품의 peak INT4 수치를 FP16 제품과 나란히 놓고 승자를 정하지 않습니다. 한국어·코드·수치 추론 등 고객 업무의 품질 기준을 먼저 정한 뒤 그 기준을 만족하는 구성끼리 비용을 비교합니다.

연결할 질의

“INT4 LLM 칩”, “양자화 정확도”, “FP8 INT8 성능 비교”

KV cache와 긴 문맥

T05 | 기술 요약 에이전트

근거와 범위

PagedAttention 논문은 KV cache 관리에서 생기는 낭비를 줄이기 위한 접근을 제시합니다. 논문의 과거 개선점은 현재의 모든 서빙 엔진과 장비에 적용되는 상수가 아닙니다. [S023]

해석

[분석] 같은 가중치 모델이라도 문맥 길이와 동시 요청 수가 커지면 서비스 메모리 요구가 증가합니다. 검색 문서를 많이 붙이는 RAG는 모델 가중치 외의 메모리 압박을 키울 수 있습니다. 문서 수와 입력 길이를 실제 사용자 분포로 설정해야 합니다.

축	확인할 입력	평가 의미
문맥 길이	평균·상위 백분위 입력	KV 최대 사용량
동시 요청	활성 세션·배치	메모리 압박
prefix 공유	공통 시스템 문구	cache 재사용
cache eviction	제거·재계산 정책	꼬리 지연
메모리 오프로딩	호스트·원격 저장	전송 지연

평가·검색에 적용

짧은 벤치마크 문장으로 큰 문서 RAG의 성능을 대신하지 않습니다. 동일 모델에 입력 길이·동시성 격자를 적용해 메모리 부족과 지연 급증 경계를 찾아야 합니다. 안정적으로 지원하는 범위를 답변에 표시합니다.

연결할 질의

“장문 RAG 추론 칩”, “KV cache 메모리”, “동시 사용자 제한”

Attention 최적화와 하드웨어

T06 | 기술 요약 에이전트

근거와 범위

FlashAttention은 GPU의 HBM과 SRAM 사이 입출력을 고려해 정확한 attention 계산을 타일링하는 방법입니다. 연산 수뿐 아니라 데이터 이동을 줄이는 소프트웨어가 성능을 바꿀 수 있음을 보여 줍니다. [S071]

해석

[분석] 새로운 칩을 기존 GPU의 최적화되지 않은 코드와 비교하면 도입 편익을 과대평가할 수 있습니다. 비교 시 각 플랫폼의 지원 가능한 최선의 안정 버전을 사용하되 모델·정확도·요청 조건은 맞춰야 합니다. 미지원 최적화가 있다면 그 사실도 결과에 남깁니다.

축	확인할 입력	평가 의미
연산 kernel	fusion·tiling	메모리 왕복
런타임	배치·스케줄링	유휴 시간
compiler	연산 배치	지원 누락
자료형	정밀도·누산	품질·성능
버전	코드·라이브러리	결과 재현

평가·검색에 적용

하드웨어 구조가 좋아도 주요 연산의 kernel이 부족하면 실제 서비스 성능은 낮을 수 있습니다. 칩 사양표와 함께 “자주 사용하는 모델에 대해 최적화된 소프트웨어가 있는가”를 기술 요약의 필수 항목으로 둡니다.

연결할 질의

“소프트웨어 최적화된 AI 칩”, “attention 가속”, “compiler 성숙도”

Speculative decoding의 평가

T07 | 기술 요약 에이전트

근거와 범위

Speculative decoding 논문은 작은 근사 모델이 제안한 토큰을 큰 모델이 검증하는 방법을 설명합니다. 논문 결과는 지정 모델·구현에 대한 것으로 모든 배포의 일정한 가속률을 뜻하지 않습니다. [S074]

해석

[분석] 작은 모델의 생성 비용, 큰 모델의 검증 비용과 제안 수락률을 함께 보아야 합니다. 여러 장비에 나누면 통신 비용이 추가됩니다. 하드웨어만 바꾸었는지 알고리즘도 바꾸었는지 구분하지 않으면 칩의 기여를 잘못 해석할 수 있습니다.

측	확인할 입력	평가 의미
draft 모델	크기·품질·비용	제안 토큰 생성
target 모델	원래 모델·정밀도	결과 검증
수락률	업무·언어·문맥	가속 편익
통신	장비 간 이동	추가 지연
정확성	샘플링 설정	출력 분포 검증

평가·검색에 적용

GPU 단독 기본 구현과 다른 장비의 speculative 구현을 비교한 결과는 전체 구성의 비교입니다. 같은 알고리즘을 양 쪽에 적용한 시험을 추가하면 하드웨어와 소프트웨어의 기여를 나누는 데 도움이 됩니다.

연결할 질의

“speculative decoding 지원”, “GPU ASIC 혼합 추론”, “토큰 속도 비교”

칩렛과 패키징의 평가

T08 | 기술 요약 에이전트

근거와 범위

Rebellions와 BOS는 칩렛 연결을 설명하고 UCle Consortium은 die-to-die 연결 표준을 제공합니다. 특정 표준의 존재는 모든 제품 간 자동 호환을 뜻하지 않습니다. [S004, S026, S075]

해석

[분석] 칩렛은 기능을 여러 다이에 나누지만 연결·패키지·테스트라는 비용이 생깁니다. 큰 모놀리식 다이와 비교할 때 수율 편익, 배선 밀도, 열 분포, 검증 범위를 함께 계산해야 합니다. 고객은 다이 성능보다 완성 패키지의 공급성과 시스템 효율을 구매합니다.

축	확인할 입력	평가 의미
다이 분할	기능·공정·면적	재사용·수율
연결	대역폭·지연·전력	확장 효율
패키지	기판·인터포저	원가·공급
검사	known-good die	불량 격리
열	핫스팟·냉각	지속 성능

평가·검색에 적용

표준 버전, 프로토콜, 패키지 방식, 지원 속도를 제품별로 기록합니다. 표준 지원·상호운용 데모·양산 검증은 각각 다른 증거 수준입니다. 패키징 파트너의 이름만으로 생산 능력을 추정하지 않습니다.

연결할 질의

“UCle 칩렛 스타트업”, “AI 칩 패키징”, “다중 다이 추론”

CXL과 메모리 풀링

T09 | 기술 요약 에이전트

근거와 범위

CXL Consortium은 CPU·가속기·메모리의 연결 표준을 제공하며 Panmnesia는 관련 스위치·컨트롤러·fabric을 소개합니다. 직접 AI 연산과 자원 연결은 서로 다른 기능입니다. [S076, S027]

해석

[분석] 메모리 풀링은 유휴 용량을 줄이거나 더 큰 모델을 수용할 가능성이 있습니다. 반면 로컬 메모리보다 접근 경로가 길어질 수 있고 운영체제·응용의 배치 정책이 중요해집니다. 용량 문제를 해결해도 처리 속도는 악화될 수 있으므로 두 지표를 같이 봅니다.

축	확인할 입력	평가 의미
확장	추가 용량 연결	모델 수용
풀링	여러 호스트의 자원 관리	유휴 감소
공유	접근·일관성 정책	응용 호환
장애	격리·복구·RAS	서비스 지속
배치	hot/cold 데이터	지연 제어

평가·검색에 적용

“CXL을 쓰면 AI가 빨라진다”는 결론을 피합니다. 실험은 hot KV cache와 cold 가중치 등을 분리하고 로컬·확장 메모리 배치 비율에 따른 지연과 비용을 측정합니다. 구매 편익은 확보한 유효 용량의 가치까지 포함합니다.

연결할 질의

“AI 메모리 확장 기업”, “CXL 스타트업”, “메모리 풀링 추론”

아날로그 인메모리 연산

T10 | 기술 요약 에이전트

근거와 범위

Mythic·Ambient Scientific·REEXEN은 서로 다른 메모리·회로 접근을 소개합니다. 같은 인메모리 연산 분류 안에 서로 저장 소자, 데이터 변환과 집적 방식이 다릅니다. [S038, S034, S066]

해석

[분석] 계산부의 효율은 전체 시스템 효율의 일부입니다. 아날로그 회로는 입력·출력 변환, 편차 보정, 디지털 제어와 함께 동작합니다. 오차를 모델이 허용하는 범위로 제한하고 실제 장치 조건에서 유지하는 것이 제품화의 핵심입니다.

축	확인할 입력	평가 의미
소자	SRAM·flash·기타	저장·연산 특성
변환	ADC·DAC	정밀도·전력
편차	개체·온도·시간	교정 비용
갱신	가중치 변경	운영 유연성
시스템	호스트·I/O	전체 효율

평가·검색에 적용

TOPS/W만 비교하지 않고 동일 정확도의 결과를 만들 때 소비하는 전체 에너지를 측정합니다. 교정·재학습·가중치 쓰기 시간도 서비스 운영의 일부입니다. 논문에서 작은 배열을 시연한 경우 완성 제품의 증거와 분리합니다.

연결할 질의

“아날로그 AI 칩”, “compute in memory”, “flash SRAM CIM 비교”

뉴로모픽과 상시 동작 센서

T11 | 기술 요약 에이전트

근거와 범위

Innatera · SynSense · BrainChip · SpiNNcloud는 서로 다른 뉴로모픽 또는 뇌 모사 계산 경로를 제시합니다. MLPerf Tiny는 작은 시스템에서 지연 · 품질과 선택적 에너지 측정을 다룹니다. [S039, S040, S041, S057, S077]

해석

[분석] 이벤트가 드문 환경은 평균 계산량을 줄일 기회가 있습니다. 하지만 실제 센서의 잡음과 이벤트 폭증은 다릅니다. 평균 정확도만으로 현장 동작을 예측할 수 없으며 오탐으로 호스트를 깨우는 전력까지 보아야 합니다.

측	확인할 입력	평가 의미
사건 빈도	정상 · 이상 비율	평균 전력
잡음	소음 · 진동 · 조명	오탐 · 미탐
지연	입력 발생부터 판단	실시간성
인코딩	신호 → 이벤트	정보 손실
도구	학습 · 변환 · debug	개발 비용

평가 · 검색에 적용

뉴로모픽은 작은 센서 칩부터 대형 연구 시스템까지 범위가 넓습니다. “뉴로모픽 기업” 질의에는 먼저 사용자가 원하는 전력 · 장치 · 알고리즘 규모를 확인하고 후보를 나누어 반환해야 합니다.

연결할 질의

“배터리 센서 AI”, “이벤트 기반 칩”, “스파이킹 신경망 가속기”

광연산과 광연결을 분리하기

T12 | 기술 요약 에이전트

근거와 범위

Lumai·Q.ANT는 광학 계산을, Lightmatter·Celestial AI는 현행 사업에서 광연결을 중심으로 설명합니다. Lightelligence는 두 경로를 모두 제공합니다. [S062, S063, S059, S061, S060]

해석

[분석] 광연산은 수학적 연산을 빛의 전파·간섭 등의 특성으로 수행하는 방향이고 광연결은 데이터를 더 효율적으로 전송하는 방향입니다. 둘 다 AI 인프라와 관련되지만 고객, 성능 지표, 경쟁 제품과 제조 검증 항목이 다릅니다.

축	확인할 입력	평가 의미
광연산	연산/초·정밀도	계산 정확도
광연결	bit/s·pJ/bit	링크 품질
광원	출력·안정성	에너지·열
패키징	결합·정렬	수율·조립
도구	모델 변환·통신 제어	시스템 통합

평가·검색에 적용

광연결 업체를 “AI 모델을 직접 실행하는 칩”의 상위 후보로 반환하지 않습니다. 다만 클러스터 확장이나 대역폭 병목을 묻는 질의에는 직접 연산기보다 더 맞는 후보일 수 있습니다. 기능 분류가 투자 분야 분류보다 먼저입니다.

연결할 질의

“광학 AI 연산”, “AI 광연결”, “CPO startup”

RISC-V·CPU·NPU의 관계

T13 | 기술 요약 에이전트

근거와 범위

Esperanto·Openchip은 RISC-V를 계산 구조의 기반으로 제시하고 SiPearl은 Arm 기반 HPC CPU를 개발합니다. ISA와 가속기의 역할은 서로 다른 분류축입니다. [S048, S049, S050]

해석

[분석] RISC-V를 쓴다는 사실만으로 AI 성능이 결정되지 않습니다. 코어 구조, 벡터·텐서 확장, 메모리, 연결과 소프트웨어가 실제 능력을 만듭니다. CPU가 AI 계산을 수행하거나 NPU를 제어할 수 있지만, 특정 모델의 주 계산 경로를 확인해야 합니다.

축	확인할 입력	평가 의미
ISA	명령어 규칙	소프트웨어 기반
코어	실행·벡터 구조	단일·다중 성능
가속기	전용 연산기	지원 워크로드
메모리	용량·대역폭	데이터 병목
툴체인	compiler·library	이전 비용

평가·검색에 적용

“오픈소스 AI 칩”이라는 질의에서 ISA가 개방되어 있는 것과 칩 RTL·SDK가 공개된 것을 구분합니다. 공개 범위와 라이선스, 실제 수정·배포 권한을 각각 확인해야 기술 통제권을 평가할 수 있습니다.

연결할 질의

“RISC-V AI 가속기”, “AI용 CPU”, “오픈소스 SDK 반도체”

벤치마크: 공정한 비교의 단위

T14 | 기술 요약 에이전트

근거와 범위

MLCommons는 시나리오와 품질 조건을 정의해 추론을 평가합니다. Tiny에서는 available과 연구·개발 시스템, closed와 open 구분도 중요합니다. [S022, S077]

해석

[분석] 같은 모델 이름이라도 가중치·정밀도·배치·입출력 길이·알고리즘이 다르면 수치를 직접 비교할 수 없습니다. 시스템 전력과 칩 TDP를 섞거나 평균 지연만으로 사용자 경험을 대표하는 것도 피해야 합니다.

측	확인할 입력	평가 의미
모델	정확한 가중치·버전	동일성
품질	정확도·업무 점수	허용 오차
요청	길이·동시성·분포	현실성
시스템	카드 수·호스트·전력	경계 일치
결과	평균·꼬리 지연·처리량	서비스 목표

평가·검색에 적용

기술 요약 에이전트는 조건이 빠진 “몇 배 빠르다”를 별도 주장 필드에 저장하고 확정 우위로 답하지 않습니다. 비교 가능한 실측 결과가 없으면 “비교 불가 / 추가 시험 필요”가 올바른 결론입니다.

연결할 질의

“가장 빠른 AI 칩”, “TOPS/W 비교”, “실측 벤치마크”

상용화 단계와 기술 증거

T15 | 기술 요약 에이전트

근거와 범위

BOS는 제품 페이지에 미래 양산 목표를, Positron은 차세대 성능의 시뮬레이션 근거를, d-Matrix는 생산 개시 발표를 제시합니다. 서로 다른 단계의 증거입니다. [S026, S046, S014]

해석

[분석] 논문→시뮬레이션→테이프아웃→실리콘 기동→샘플→인증→양산→유상 출하→반복 구매를 별도 이벤트로 기록합니다. 특정 단계의 공개가 다음 단계의 완료를 의미하지 않습니다. 증거가 오래되었으면 최신 상태를 미확인으 로 표시합니다.

축	확인할 입력	평가 의미
설계	시뮬레이션·논문	실리콘 미검증
샘플	보드·모델 실행	수율·공급 미검증
생산	제조·검사 체계	판매 규모 미검증
출하	고객 인도	검수·매출 별도
반복 구매	추가 유상 주문	지속 수요 신호

평가·검색에 적용

기술 위험은 단계가 진행되며 바뀝니다. 초기에는 구현 가능성, 후반에는 공급·소프트웨어 유지·고객 수익성이 중요 합니다. 단일 기술 점수 대신 어떤 위험이 해소되었는지 기록하면 투자 판단에 필요한 설명이 선명해집니다.

연결할 질의

“양산된 AI 칩 스타트업”, “실리콘 검증 기업”, “시뮬레이션 성능”

AI 인프라 수요와 전력 제약

T16 | 시장성 평가 에이전트

근거와 범위

IEA의 2026년 4월 발표는 2025년 데이터센터 전력 수요 증가율을 17%, 세계 전체 전력 수요 증가율을 3%로 제시합니다. 데이터센터 수요가 2030년까지 두 배가 될 것으로 전망합니다. [S020]

해석

[분석] 전력 수요 증가는 더 많은 계산 인프라를 의미할 수 있지만 특정 칩 스타트업의 매출을 직접 예측하지는 못합니다. 전력 확보·냉각·설치 공간이 제한된 고객에게는 최대 성능보다 확보한 전력 안에서 처리하는 유효 업무량이 구매 기준이 됩니다.

축	확인할 입력	평가 의미
전력 계약	확보 가능한 MW	설치 한계
냉각	공랭·수랭·열 밀도	배치 가능성
이용률	시간대별 실제 부하	유효 비용
서비스 목표	지연·품질	판매 가능한 처리량
공급 일정	전력·장비 도입	매출 발생 시점

평가·검색에 적용

전력 효율을 강조하는 업체의 질문은 “칩이 적게 쓰는가”에서 “고객이 같은 전력 한도에서 더 많은 유효 서비스를 제공하는가”로 확장해야 합니다. 에너지 효율 개선이 전체 수요 감소를 뜻한다는 가정도 피합니다.

연결할 질의

“전력 제약 데이터센터”, “저전력 LLM 추론”, “AI 전력 수요 전망”

시장 규모: TAM · SAM · SOM

T17 | 시장성 평가 에이전트

근거와 범위

WSTS는 전체 반도체 시장을, IEA는 데이터센터 전력을 다룹니다. 모집단과 단위가 다르므로 어느 숫자도 개별 AI 칩 업체의 접근 시장으로 바로 바꿀 수 없습니다. [S021, S020]

해석

[분석] TAM은 해당 문제에 대한 전체 지출, SAM은 지역·제품·지원 모델·영업 경로상 접근 가능한 부분, SOM은 일정 기간 실제 확보 가능한 매출로 정의해 계산합니다. 기업마다 판매 단위가 칩·카드·랙·IP·토큰으로 다르므로 시장 분 모를 맞춰야 합니다.

축	확인할 입력	평가 의미
칩 판매	대상 장치 수 × 탑재율 × 단가	장치 시장 ≠ 칩 시장
서버 판매	대상 고객 × 도입 대수 × 가격	가속기 중복 계산
IP	설계 채택 × 라이선스 · 로열티	양산 시차
클라우드	유상 토큰 × 단가	무료 · 할인 사용량
연결 칩	시스템 구성 × 채택률	연산 시장과 분리

평가·검색에 적용

확인된 단가·고객 수가 없으면 시장규모 숫자를 만들지 않습니다. 대신 어떤 입력이 비어 있고 어떤 범위의 시나리오를 계산할지 제시합니다. 같은 고객 지출을 칩과 랙 매출에 중복 합산하지 않아야 합니다.

연결할 질의

“AI 칩 시장 규모”, “접근 가능한 시장”, “칩 매출 추정”

기관 전망의 시점과 불확실성

T18 | 시장성 평가 에이전트

근거와 범위

IEA의 2025년 Energy and AI와 2026년 후속 발표는 서로 다른 전망 시점을 가집니다. Deloitte의 2026 산업 전망과 WSTS의 계절별 전망도 발표 시점과 가정을 보존해야 합니다. [S081, S020, S078, S021]

해석

[분석] 최신 자료가 과거 전망을 대체할 때 과거 수치를 삭제하면 예측 변화의 맥락을 잃습니다. 예측 대상 연도, 발표일, 실제 실적 여부, 기준 시나리오와 민감도를 함께 저장합니다. 서로 다른 기관의 수치를 단순 평균 내면 모집단 차이를 숨길 수 있습니다.

축	확인할 입력	평가 의미
published_at	전망 발표 시점	빈티지 구분
target_period	예측하는 기간	시간축 일치
measure	매출·출하·전력	단위 일치
scenario	기준·상방·하방	가정 구분
actual_or_forecast	실적·전망	확정성 구분

평가·검색에 적용

시장성 에이전트가 “현재 시장은 X”라고 답하려면 실적과 전망을 먼저 구분해야 합니다. 출처가 오래된 경우 오래되었다고 명시하고 새로운 사건이 해당 전망을 바꾸는지 확인합니다.

연결할 질의

“2026 전망과 실적”, “시장 전망 업데이트”, “AI 인프라 성장률”

온프레미스·주권형 AI 수요

T19 | 시장성 평가 에이전트

근거와 범위

OECD는 국가 AI 전략에 맞는 계산 역량 계획, 접근성·회복력·보안·지속가능성의 중요성을 설명합니다. 기업의 온프레미스 수요와 국가의 계산 전략은 연결될 수 있지만 동일하지 않습니다. [S079]

해석

[분석] 데이터를 내부에 보관해야 하는 고객은 API 가격만으로 공급자를 선택하지 않을 수 있습니다. 하지만 자체 서버는 장비 이용률·운영 인력·업데이트 비용이 필요합니다. 국가 내 설계, 제조, 데이터 저장과 소프트웨어 통제권은 각각 다른 의미의 주권입니다.

축	확인할 입력	평가 의미
데이터 위치	저장·처리 지역	내부 운영 필요
운영 주체	관리 권한·지원	통제권
모델	라이선스·배포 권한	사용 가능성
공급	부품·제조·지원	지속성
경제성	이용률·인력·장비	클라우드 대비 비용

평가·검색에 적용

국내 기업이라는 이유만으로 모든 부품 공급이 국내라고 답하지 않습니다. 주권형 AI 질의에는 사용자가 보호하려는 것이 데이터인지 설계 기술인지 공급망인지 구분하고 후보를 제시합니다.

연결할 질의

“사내 AI 서버”, “소버린 AI 반도체”, “국내 설계·해외 생산”

산업 비전과 품질 검사

T20 | 시장성 평가 에이전트

근거와 범위

Mobilint·Hailo·Axelera·MemryX는 산업 영상이나 엣지 분석을 공개 응용으로 제시합니다. 제품 소개는 해당 고객 업무의 불량 검출 성능을 직접 입증하지는 않습니다. [S008, S028, S030, S032]

해석

[분석] 제조 현장에서는 정확도 평균보다 놓친 불량량의 비용과 정상 제품의 과잉 배제가 중요할 수 있습니다. 장치의 처리 속도는 라인 takt time과 카메라 수를 충족해야 합니다. 학습 모델 변경과 장비 조명 변동이 실제 운영 비용을 만듭니다.

축	확인할 입력	평가 의미
검출 품질	미검·과검·결함 종류	생산 손실
영상 입력	해상도·카메라 수	대역폭
지연	검사→배출 액추에이터	제어 시간
변화	조명·제품·모델	재검증
운영	로그·원격 업데이트	유지보수

평가·검색에 적용

반도체 SEM 이미지처럼 경계 품질이 중요한 응용은 분류 정확도만으로 판단할 수 없습니다. 고객 모델의 분할·검출 지표를 양자화 전후로 비교하고 실제 이미지 크기의 타일링 비용도 포함해야 합니다.

연결할 질의

“공장 검사 NPU”, “SEM 이미지 추론 가속”, “다중 카메라 AI”

로봇과 Physical AI

T21 | 시장성 평가 에이전트

근거와 범위

IFR의 2025년 발표는 2024년 산업용 로봇 신규 설치를 약 54만 2,000대로 제시합니다. 이는 전체 산업용 로봇 통계이며 신규 AI 칩이 각 로봇에 반드시 추가된다는 뜻은 아닙니다. [S080]

해석

[분석] 로봇 계산은 영상 인식뿐 아니라 센서 융합, 계획, 제어, 통신을 포함합니다. 크고 강력한 모델을 탑재해도 제어 지연과 열·배터리 제약이 맞아야 합니다. “Physical AI”라는 용어보다 실제 작업과 플랫폼을 기준으로 후보를 분류합니다.

축	확인할 입력	평가 의미
감지	카메라·LiDAR·촉각	입력 대역폭
판단	비전·언어·행동 모델	정확도·지연
제어	주기·deadline	시간 보장
장치	전력·열·중량	탑재 가능성
운영	안전 정지·로그	고장 대응

평가·검색에 적용

로봇당 판매 단가를 추정할 때 가속기 수·호스트·센서 비용을 구분합니다. 연구 시연과 현장 판매는 다른 단계이며, 일정한 환경의 데모를 다양한 작업의 자율성으로 확대하지 않습니다.

연결할 질의

“로봇용 AI 칩”, “VLA 가속기”, “Physical AI 반도체”

자동차: 설계 채택에서 양산까지

T22 | 시장성 평가 에이전트

근거와 범위

BOS는 유럽 OEM과 ADAS 칩셋 개발 계약을 발표했고 제품 페이지에는 이후 양산 목표가 제시됩니다. 개발 계약과 차량 양산은 별도 상태입니다. [S082, S026]

해석

[분석] 자동차는 차량 플랫폼 일정·온도·신뢰성·장기 공급·기능 안전 요구가 중요합니다. 소비자용 보드에서 높은 처리량을 보였다고 차량 제품에 곧바로 채택되는 것은 아닙니다. 고객의 설계 변경 마감과 제품 검증 기간을 함께 추적합니다.

축	확인할 입력	평가 의미
설계 계약	범위·책임·개발비	수익 구조
샘플	보드·실리콘 버전	기능 검증
검증	환경·안전·신뢰성	차량 요구
양산	고객 SOP·생산량	출하 시점
유지	장기 공급·업데이트	계약 책임

평가·검색에 적용

ADAS·IVI·차량 내 생성형 AI는 서로 다른 지연·안전·연산 요구를 가집니다. 하나의 칩이 모든 자동차 문제를 해결한다고 답하지 않습니다. 양산 로열티나 공급 매출은 고객 차종의 실제 채택률에 달려 있습니다.

연결할 질의

“차량용 AI 칩 스타트업”, “ADAS 칩셋”, “자동차 양산 일정”

배터리 기기의 사업성

T23 | 시장성 평가 에이전트

근거와 범위

Syntiant·Ambient Scientific·AONDevices·Innatera는 상시 동작하는 저전력 감지 응용을 소개합니다. 이 시장에서는 서버용 TOPS와 다른 구매 지표가 필요합니다. [S033, S034, S035, S039]

해석

[분석] 배터리 수명은 칩의 active 전력뿐 아니라 sleep 전력, 센서·무선·호스트, 이벤트 빈도에 좌우됩니다. 드물게 사용하는 추론 기능이 항상 켜진 회로를 추가하면 전체 수명이 오히려 줄 수 있습니다. 실제 하루 사용 패턴으로 에너지를 적분해야 합니다.

축	확인할 입력	평가 의미
대기	상시 소비 전력	기본 수명
추론	이벤트당 에너지	활성 비용
오탐	불필요한 기동	숨은 비용
통신	전송 횟수·거리	무선 비용
교체	방문·폐기·부품	고객 총비용

평가·검색에 적용

고객이 배터리 교체 인건비를 많이 쓰는 경우 작은 에너지 개선도 큰 편익이 될 수 있습니다. 반대로 충전이 쉬운 장치에서는 정확도·가격·개발 속도가 더 중요한 기준일 수 있습니다.

연결할 질의

“코인셀 AI 칩”, “상시 음성 감지”, “센서 배터리 수명”

IP 사업과 칩 판매의 차이

T24 | 시장성 평가 에이전트

근거와 범위

AiM Future·HyperAccel·Synthara·Tenstorrent는 IP 또는 관련 통합 경로를 공개합니다. 칩 판매 기업과 같은 출하량 지표만으로 비교하기 어렵습니다. [S025, S006, S042, S017]

해석

[분석] IP는 초기 라이선스·개발 지원·고객 양산 로열티가 서로 다른 시점에 발생할 수 있습니다. 적은 자본으로 여러 고객 제품에 들어갈 가능성이 있지만 고객 개발 지연과 통합 비용에 노출됩니다. 매출의 반복성과 엔지니어 투입량을 같이 보아야 합니다.

축	확인할 입력	평가 의미
라이선스	일시금·사용 범위	초기 수익
NRE	맞춤 개발·검증	인력 비용
로열티	출하·단가·최저 보장	장기 수익
지원	버전·공정·수명	유지 비용
권리	독점·수정·재사용	확장 가능성

평가·검색에 적용

“고객 수”가 평가 계약인지 정식 라이선스인지 양산 고객인지 구분합니다. 많은 PoC가 소수 엔지니어를 분산시키면 수익성이 나빠질 수 있습니다. 실제 테이프아웃 전환율과 장기 로열티 기반을 확인해야 합니다.

연결할 질의

“NPU IP 라이선스”, “반도체 로열티”, “팹리스 사업 모델”

API 서비스와 시스템 판매

T25 | 시장성 평가 에이전트

근거와 범위

Groq는 현행 발표에서 추론 클라우드 확대를, Cerebras와 SambaNova는 API와 시스템 경로를 함께 소개합니다. 기술 계보와 현재 수익 모델이 항상 같지는 않습니다. [S054, S052, S053]

해석

[분석] 칩·서버 판매는 출하와 지원 계약을, API 사업은 토큰 매출과 인프라 이용률을 중심으로 봅니다. 동일 기술도 서비스로 판매하면 장비 재고·고객 지원·전력·수요 변동의 부담이 회사에 남습니다.

축	확인할 입력	평가 의미
시스템 판매	판매 가격·원가	출하 매출
서비스	유상 토큰·할인	반복 매출
장비 이용률	유헴·최대 부하	서비스 원가
고객 전환	무료→유상·이탈	지속성
모델 운영	업데이트·지원	차별화 비용

평가·검색에 적용

개발자 계정 수를 유상 고객 수로 바꾸지 않습니다. 빠른 응답은 고객 편익이지만 프리미엄 요금을 받을 수 있는지는 별도 실험이 필요합니다. API 비교는 가격의 조회일과 과금 단위를 반드시 함께 기록합니다.

연결할 질의

“AI 칩 기반 클라우드”, “추론 API 사업성”, “토큰당 비용”

상장·인수·라이선스 사례

T26 | 시장성 평가 에이전트

근거와 범위

Cerebras는 상장, Graphcore·Kinara·Celestial AI는 인수 완료, Groq는 비독점 기술 라이선스와 사업 전환 사례입니다. 이 상태들은 서로 바뀌 쓸 수 없습니다. [S067, S068, S058, S069, S070]

해석

[분석] 스타트업 탐색은 기업의 기술 적합성과 투자 대상 상태를 별도로 판단해야 합니다. 독립 비상장 기업을 찾는 질의에 인수된 자회사를 넣으면 후보 목록은 기술적으로 맞아도 실행 가능한 투자 탐색에는 부적합해집니다.

축	확인할 입력	평가 의미
독립 법인	현재 주주·지배구조	대상 식별
상장	거래소·공시	비교군 분리
인수 완료	종결 발표·통합	독립 후보 제외
라이선스	권리 범위·인력 이동	인수와 구분
합병	존속 법인·별칭	중복 제거

평가·검색에 적용

브랜드가 살아 있어도 독립 기업이 아닐 수 있습니다. 인수 발표와 종결도 구분합니다. 회수 사례를 분석할 때 금액보다 기술·고객·인력·공급망 중 무엇이 거래의 목적이었는지 확인하는 것이 유용합니다.

연결할 질의

“인수되지 않은 AI 칩 기업”, “상장 AI 반도체”, “인수 사례”

공급망과 제조성

T27 | 시장성 평가 에이전트

근거와 범위

Deloitte의 2026 전망은 통합 시스템과 공급망 위험을 산업의 주요 과제로 다룹니다. d-Matrix는 공개 생산 발표에서 공정·기판·메모리 선택을 공급 전략과 연결합니다. [S078, S014]

해석

[분석] 팹리스 기업의 위험은 설계 성능에만 있지 않습니다. 웨이퍼·패키징·메모리·테스트·보드 부품 중 하나가 늦어도 고객 출하가 지연됩니다. 설계가 잘 작동하는 것과 목표 원가·수량으로 반복 생산하는 것은 다른 증거를 요구합니다.

축	확인할 입력	평가 의미
웨이퍼	공정·계약·capacity	생산 가능성
패키징	기판·HBM·조립	병목
수율	불량·재작업	원가
테스트	시간·장비·coverage	출하 속도
재고	선발주·회전	현금 부담

평가·검색에 적용

공급 계약이 있다는 발표만으로 납기와 원가를 확정하지 않습니다. 양산 단계 기업에는 고객 수요보다 앞선 재고 투자와 현금 소모를 확인하고, 초기 기업에는 다음 설계 수정에 필요한 자금과 시간을 확인합니다.

연결할 질의

“AI 칩 양산 위험”, “패키징 공급망”, “팹리스 현금 소모”

고객 증거의 강도

T28 | 시장성 평가 에이전트

근거와 범위

본 보고서의 많은 채택·생산·투자 정보는 회사 발표입니다. 이는 발표가 존재한다는 근거이며 계약 원본·고객의 독립 측정·감사 매출을 대신하지 않습니다.

해석

[분석] 평가 에이전트는 주장을 하나의 점수로 압축하기 전에 증거 유형을 분류해야 합니다. 고객명이 있는 사례와 익명 파이프라인, 무상 PoC와 반복 유상 주문은 사업 위험에 주는 정보량이 다릅니다. 미공개를 실패로 단정하지도 않습니다.

축	확인할 입력	평가 의미
최상위 근거	반복 유상 주문·실사용 지표	지속 수요
상업 근거	유상 계약·검수·매출	전환 확인
제품 근거	고객 샘플·시험 보고서	기술 적용
협력 근거	MOU·생태계·공동개발	초기 관계
일반 주장	익명 고객·시장 전망	추가 확인

평가·검색에 적용

긍정 자료의 수를 합산하는 방식은 같은 보도자료 재배포를 여러 근거로 셀 수 있습니다. 원발표와 재인용을 묶고, 고객이 직접 확인한 항목과 공급자의 주장을 분리하면 과대평가를 줄일 수 있습니다.

연결할 질의

“실제 고객이 있는 스타트업”, “PoC와 매출 차이”, “고객 증거 검증”

TCO와 민감도 분석

T29 | 시장성 평가 에이전트

근거와 범위

이 장은 특정 기업의 실제 비용 계산이 아니라 비교를 위한 분석 틀입니다. 비공개 단가·마진·수율을 임의로 채워 기업별 수익률을 산출하지 않습니다.

해석

[분석] 연간 총비용에는 장비의 연간 배분 비용, 전력·냉각, 호스트·네트워크, 유지보수와 모델 이전 비용을 넣습니다. 유효 처리량은 품질과 지연 목표를 만족한 결과만 셉니다. 비용을 이 처리량으로 나누면 서비스 기준 비교가 가능합니다.

축	확인할 입력	평가 의미
장비	실구매가·수명·잔존가치	연간 배분
운영	전력·냉각·공간	고정·변동비
소프트웨어	이전·검증·지원	일회성·반복
이용률	일별 부하·판매율	유효 처리량
위험	장애·지연·교체	예비 비용

평가·검색에 적용

이용률이 낮으면 빠르고 비싼 장비의 단위 비용이 커질 수 있습니다. 기준·낮은 수요·높은 수요 시나리오를 만들고, 전 기요금·장비 가격·모델 크기 변화에 결과가 얼마나 민감한지 확인합니다. 없는 숫자는 범위조차 꾸며 넣지 않습니다.

연결할 질의

“토큰당 총비용”, “GPU 대체 경제성”, “AI 칩 도입 손익분기점”

국내외 후보를 함께 비교하는 방법

T30 | 시장성 평가 에이전트

근거와 범위

이번 목록은 국내 8개와 해외 42개 기업·사업 사례로 구성합니다. 국내 목록에는 연결 기술인 Panmnesia를 포함하고, 해외 목록에도 CPU·광연결·네트워크와 상장·인수 비교 기업을 명시합니다.

해석

[분석] 지역을 먼저 필터링한 뒤 워크로드·제품 형태·현재 상태를 맞춥니다. 국내 지원과 영업 접근성이 중요한 고객과 국제 클라우드의 대규모 공급이 필요한 고객은 평가 가중치가 다릅니다. 국적 자체를 기술력의 대리 지표로 쓰지 않습니다.

축	확인할 입력	평가 의미
1차 조건	지역·법인·상태	실행 가능한 대상
2차 조건	부하·전력·형태	제품 적합성
3차 근거	샘플·출하·고객	검증 정도
비교 범위	동일 모델·시스템	공정성
결과	일치 이유·미확인	설명 가능한 후보

평가·검색에 적용

기업 수를 많이 확보하는 것과 모든 질의에 많이 반환하는 것은 다릅니다. 넓은 데이터베이스에서 사용자의 필수 조건을 충족하는 후보만 근거와 함께 제시합니다. 조건이 부족하면 성능 순위 대신 용도별 후보군을 보여 줍니다.

연결할 질의

“국내외 AI 칩 설계 스타트업”, “엣지와 데이터센터 후보”, “기술 적합성 탐색”

원본·정형 사실·검색 청크 저장

권장 구조

PDF는 검토·배포용 기준 문서로 보존하고, 추출 텍스트와 원문 URL을 함께 저장합니다. 정형 조건은 관계형 DB 또는 JSON 레코드에 두고 검색 본문에는 키워드·벡터 색인을 함께 사용합니다. 숫자 필터를 벡터 유사도만으로 결정하지 않습니다.

필드	의미 / 예시
company_id / aliases	기업 단일 ID와 한글·영문·옛 이름
document_id / page	문서 버전과 실제 PDF 페이지
topic / agent_tags	사업·기술·시장·상태 / 사용할 에이전트
source_id / source_url	S010 등 원문으로 돌아갈 근거
evidence_type	company_claim, paper, forecast, analysis, unknown
published_at / retrieved_at	발행일 미표기는 null / 조회일 2026-09-29
metric / unit / conditions	INT8 TOPS, 카드 TDP, 실측 여부 등
event_type / event_date	투자·샘플·생산·출하·인수·상장

청크 구성 제안

기업 두 페이지를 통째로 하나로 넣기보다 제목과 의미 단위로 분리합니다. 회사 사실과 작성자 분석을 분리하되 company_id로 묶습니다. 초기 청크 길이는 약 400-800 토큰 범위에서 시험하고 표는 제목·단위·조건과 함께 보존합니다. 이 길이는 권장 시작값이며 검색 평가로 조정해야 합니다.

원문 수집 경계

로그인·유료 자료는 사용 권한을 확인한 범위만 수집합니다. 공개 페이지에서도 불필요한 메뉴·광고·채용 항목을 제외하고 제품 본문·날짜·출처를 보존합니다. 표의 상충 수치는 임의로 고쳐 하나로 만들지 않습니다.

세 에이전트의 검색·출력 계약

에이전트	검색 대상	출력
스타트업 탐색	기업 프로필·제품·상태·지역	조건 일치 후보, 일치 이유, 제외 이유, 근거
기술 요약	제품 사양·논문·개발 문서	구조, 장점 가설, 한계, 조건, 미확인
시장성 평가	고객 문제·기관 자료·상용화 이벤트	수요 근거, 사업 모델, 위험, 추가 자료

검색 흐름

질의에서 필수 조건 추출 → 기업 상태·지역·제품 형태 필터 → 키워드 및 의미 검색 → 근거 청크 재정렬 → 기업별 중복 제거 → 답변과 출처 생성 순서로 구성합니다. 같은 회사의 공식 발표와 재배포 뉴스는 독립 근거 여러 건으로 세지 않습니다.

기술 요약 출력 예시

기업 / 제품 / 핵심 구조 / 지원 모델과 정밀도 / 성능 조건 / 장점 가설 / 한계 / 확인하지 못한 값 / source_ids.
source_ids가 없는 성능 숫자는 생성하지 않도록 검수합니다. 모델 이름이 같아도 버전·양자화가 다르면 별도 결과로 취급합니다.

시장성 출력 예시

고객군 / 해결 문제 / 수요 근거 / 판매 단위 / 상용화 상태 / 확인된 고객 증거 / 경쟁 대안 / 위험 / 추가 확인 자료. 시장 성장만으로 기업 매출을 예측하거나 미확인 재무 항목을 0점으로 채우지 않습니다.

상태 공유

탐색이 반환한 company_id와 source_ids를 다음 에이전트에 전달합니다. 기술·시장 에이전트는 동일 회사 ID에 결과를 누적하고 검증된 사실과 분석을 분리합니다. 후보 재탐색 시 이미 평가한 ID와 제외 이유를 함께 사용하면 같은 회사를 반복 조사하는 낭비를 줄일 수 있습니다.

검색 평가용 질의와 정답 조건

시험 질의	기대하는 답변의 조건
국내 5W 이하 NPU	DEEPX의 회사 사양을 후보 근거로 제시하되 전체 장치 전력과 구분
DEEPX는 200 TOPS인가	25 TOPS INT8 사양과 GPU-class 홍보 표현을 구분
Mobilint는 20W인가 25W인가	본문 전력 표현과 표의 TDP를 각각 보존
Asimov 실측 성능은	시뮬레이션과 2027년 예정 제품임을 구분
Groq가 NVIDIA에 인수됐나	비독점 라이선스와 회사 전체 인수를 구분
Graphcore 독립 스타트업인가	SoftBank 완전 자회사라는 확인 상태 반영
AI 행렬 연산용 광 칩	광연산과 Lightmatter 등 광연결을 구분
상장되지 않은 후보만	확인된 상장·인수 사례 제외, 미확인 상태를 명시

정량 검수 항목

필수 조건 충족률, 후보 중복률, 근거 인용의 정확성, 숫자·단위 일치율, 날짜 오류, 미확인 항목의 올바른 유보를 측정합니다. 답변이 자연스럽다는 이유만으로 통과시키지 않습니다. 사람이 확인한 질의·근거 쌍으로 평가 세트를 만듭니다.

경계 사례

“가장 좋은 칩”처럼 기준이 없는 질문에는 용도·전력·가격·상용화 조건을 분리합니다. 후보가 세 곳 미만이면 없는 회사를 채우지 않습니다. 출처가 부족하면 보류 이유와 필요한 자료를 출력합니다.

갱신·충돌·출처 관리

변경을 이벤트로 저장

제품 사양 변경, 투자 유치, 인수·합병, 상장, 샘플·양산·출하를 별도 이벤트로 보존합니다. 새 페이지가 과거 제품 값을 바꾸면 이전 스냅샷을 지우지 않고 valid_from·valid_to 또는 supersedes 관계를 저장합니다.

상황	처리 규칙
날짜 없는 홈페이지	조회일만 저장. 제품 출시일을 추정하지 않음
서로 다른 사양	제품 버전·단위·측정 경계·발표일을 먼저 비교
시장 전망 개정	기관·대상 연도·발표 빈티지·시나리오 유지
브랜드·법인 변화	옛 이름을 alias로 연결하고 법인 관계 확인
원문 접근 실패	마지막 확인본과 실패 시점 표시, 새로운 사실 생성 금지
재배포 보도자료	원발표와 묶어 독립 근거 중복 계산 방지

출처 목록의 사용

다음 10페이지의 출처는 원문으로 돌아가기 위한 주소록입니다. 기업별 사실은 본문의 출처 ID에 연결됩니다. 일부 보완 자료는 제품 세대·법인 상태·개발 도구 확인에 사용했습니다. 공식 사이트라는 사실만으로 홍보 주장이 독립적으로 검증되는 것은 아닙니다.

이 자료에 없는 것

모든 기업의 감사 재무제표, 계약 원본, 가격 견적, 독립 하드웨어 실험, 유료 산업 보고서 전체는 포함하지 않습니다. 작성자의 시장 분석과 실험 제안은 공개 근거를 해석한 것이며 기업의 확정 실적이 아닙니다.

기준 문서로 활용

업데이트 때 바뀐 기업·수치·이벤트만 검토할 수 있도록 문서 버전과 페이지를 함께 기록합니다. 서비스의 최종 답변은 사용자가 요구한 시점에 맞추고, 이 문서 기준일 이후의 상태를 자동으로 최신이라고 표현하지 않습니다.

출처 목록 01 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S001 | FuriosaAI · 발행일 미표기

RNGD product

<https://furiosa.ai/rngd>

S002 | FuriosaAI · 2025-07-30

Announcing FuriosaAI’s \$125M Series C Bridge Funding

<https://furiosa.ai/blog/announcing-furiosaaais-125m-series-c-bridge-funding-to-scale-sustainable-ai-compute>

S003 | Kim et al. / ISCA · 2024

TCP: A Tensor Contraction Processor for AI Workloads (Industrial Product)

<https://furiosa.ai/download/FuriosaAI-tensor-contraction-processor-isca24>

S004 | Rebellions · 발행일 미표기

REBEL100 product

<https://kr.rebellions.ai/rebellions-product/rebel100/>

S005 | Rebellions · 2026-03-30

Closes \$400 Million Pre-IPO and Launches RebelRack and RebelPod

<https://rebellions.ai/newsroom/rebellions-closes-400-million-pre-ipo-and-launches-rebelrack-and-rebelpod-to-accelerate-global-expansion/>

S006 | HyperAccel · 발행일 미표기

LPU IP

https://hyperaccel.ai/ha_product/lpu-ip/

S007 | HyperAccel · 웹페이지 2025-09-19

Raises 55 Billion KRW in Series A Funding

<https://hyperaccel.ai/hyperaccel-raises-55-billion-krw-in-series-a-funding-for-llm-focused-ai-semiconductor-development/>

S008 | Mobilint · 발행일 미표기

ARIES

<https://www.mobilint.com/aries>

S009 | Mobilint · 발행일 미표기

About / History

<https://www.mobilint.com/about>

출처 목록 02 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S010 | DEEPX · 발행일 미표기

DX-M1

<https://deepx.ai/products/dx-m1/>

S011 | DEEPX / PR Newswire · 2024-05-10

Korean Semiconductor Industry Titans Back DEEPX in Series C Funding Round

<https://www.prnewswire.com/apac/news-releases/korean-semiconductor-industry-titans-back-deepx-in-series-c-funding-round-302141177.html>

S012 | d-Matrix · 발행일 미표기

Product

<https://www.d-matrix.ai/product/>

S013 | d-Matrix · 2025-11-12

Raises \$275 Million to Power the Age of AI Inference

<https://www.d-matrix.ai/announcements/d-matrix-raises-275-million-to-power-the-age-of-ai-inference/>

S014 | d-Matrix · 2026-06-09

Corsair AI Inference Platform Enters Full Production

<https://www.d-matrix.ai/announcements/d-matrix-corsair-ai-inference-platform-enters-full-production-to-meet-customer-demand/>

S015 | Tenstorrent · 발행일 미표기

Deploy

<https://tenstorrent.com/deploy>

S016 | Tenstorrent · 발행일 미표기

Developers

<https://tenstorrent.com/developers>

S017 | Tenstorrent · 2023-10-10

BOS and Tenstorrent Partner to Develop Automotive Semiconductor

<https://tenstorrent.com/newsroom/bos-and-tenstorrent-partner-to-develop-automotive-semiconductor>

S018 | Etched · 2026-06-30

Frontier Inference Clusters

<https://www.etched.com/progress/frontier-inference-clusters>

출처 목록 03 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S019 | Etched · 2026-08-18

From Zero to One

<https://www.etched.com/progress/from-zero-to-one>

S020 | IEA · 2026-04-16

Data centre electricity use surged in 2025...

<https://www.iea.org/news/data-centre-electricity-use-surged-in-2025-even-with-tightening-bottlenecks-driving-a-scramble-for-solutions>

S021 | WSTS · 2026년 봄 전망

Recent News Release / Spring 2026 Forecast

<https://www.wsts.org/76/Recent-News-Release>

S022 | MLCommons · 동적 페이지

MLPerf Inference: Datacenter

<https://mlcommons.org/benchmarks/inference-datacenter/>

S023 | Kwon et al. · 2023-09-12

Efficient Memory Management for Large Language Model Serving with PagedAttention

<https://arxiv.org/abs/2309.06180>

S024 | SEMI · 발행일 미표기

Semiconductor Manufacturing Monitor

<https://www.semi.org/en/products-services/market-data/manufacturing-monitor>

S025 | AiM Future · 발행일 미표기

AiM Future 공식 제품·기술 소개

<https://aimfuture.ai/en/>

S026 | BOS Semiconductors · 발행일 미표기

BOS Semiconductors 공식 제품·기술 소개

<https://www.bos-semi.com/product>

S027 | Panmnesia · 발행일 미표기

Panmnesia 공식 제품·기술 소개

<https://www.panmnesia.com/>

출처 목록 04 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S028 | Hailo · 발행일 미표기

Hailo 공식 제품·기술 소개

<https://hailo.ai/products/>

S029 | Kneron · 발행일 미표기

Kneron 공식 제품·기술 소개

<https://www.kneron.com/>

S030 | Axelera AI · 발행일 미표기

Axelera AI 공식 제품·기술 소개

<https://axelera.ai/ai-accelerators>

S031 | SiMa.ai · 발행일 미표기

SiMa.ai 공식 제품·기술 소개

<https://sima.ai/mlsoc-family/>

S032 | MemryX · 발행일 미표기

MemryX 공식 제품·기술 소개

<https://memryx.ai/>

S033 | Syntiant · 발행일 미표기

Syntiant 공식 제품·기술 소개

<https://www.syntiant.com/>

S034 | Ambient Scientific · 발행일 미표기

Ambient Scientific 공식 제품·기술 소개

<https://www.ambientscientific.ai/>

S035 | AONDevices · 발행일 미표기

AONDevices 공식 제품·기술 소개

<https://aondevices.com/>

S036 | EdgeCortex · 발행일 미표기

EdgeCortex 공식 제품·기술 소개

<https://www.edgecortex.com/en/>

출처 목록 05 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S037 | NEUCHIPS · 발행일 미표기

NEUCHIPS 공식 제품·기술 소개

<https://www.neuchips.ai/>

S038 | Mythic · 발행일 미표기

Mythic 공식 제품·기술 소개

<https://www.mythic.ai/>

S039 | Innatera · 발행일 미표기

Innatera 공식 제품·기술 소개

<https://www.innatera.com/>

S040 | SynSense · 발행일 미표기

SynSense 공식 제품·기술 소개

<https://www.synsense.ai/>

S041 | SpiNNcloud · 발행일 미표기

SpiNNcloud 공식 제품·기술 소개

<https://spinncloud.com/>

S042 | Synthara · 발행일 미표기

Synthara 공식 제품·기술 소개

<https://synthara.ai/>

S043 | SEMRON · 발행일 미표기

SEMRON 공식 제품·기술 소개

<https://www.semron.com/>

S044 | Fractile · 발행일 미표기

Fractile 공식 제품·기술 소개

<https://www.fractile.ai/>

S045 | MatX · 발행일 미표기

MatX 공식 제품·기술 소개

<https://matx.com/>

출처 목록 06 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S046 | Positron · 발행일 미표기

Positron 공식 제품·기술 소개

<https://www.positron.ai/>

S047 | Tensordyne · 발행일 미표기

Tensordyne 공식 제품·기술 소개

<https://www.tensordyne.ai/>

S048 | Esperanto Technologies · 발행일 미표기

Esperanto Technologies 공식 제품·기술 소개

<https://www.esperanto.ai/>

S049 | Openchip · 발행일 미표기

Openchip 공식 제품·기술 소개

<https://openchip.com/solutions/>

S050 | SiPearl · 발행일 미표기

SiPearl 공식 제품·기술 소개

<https://sipearl.com/>

S051 | Enfabrica · 발행일 미표기

Enfabrica 공식 제품·기술 소개

<https://www.enfabrica.net/>

S052 | Cerebras · 발행일 미표기

Cerebras 공식 제품·기술 소개

<https://www.cerebras.ai/>

S053 | SambaNova · 발행일 미표기

SambaNova 공식 제품·기술 소개

<https://sambanova.ai/>

S054 | Groq · 2026-06-22

Groq 공식 제품·기술 소개

<https://groq.com/newsroom/groq-raises-usd650m-to-scale-its-ai-inference-cloud-business>

출처 목록 07 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S055 | Graphcore · 2024-07

Graphcore 공식 제품·기술 소개

<https://www.graphcore.ai/posts/graphcore-joins-softbank-group-to-build-next-generation-of-ai-compute>

S056 | Blaize · 발행일 미표기

Blaize 공식 제품·기술 소개

<https://www.blaize.com/>

S057 | BrainChip · 발행일 미표기

BrainChip 공식 제품·기술 소개

<https://brainchip.com/>

S058 | Kinara · 2025-10-27

Kinara 공식 제품·기술 소개

<https://www.nxp.com/company/about-nxp/smarter-world-blog/BL-EDGE-AI-WITH-KINARA>

S059 | Lightmatter · 발행일 미표기

Lightmatter 공식 제품·기술 소개

<https://lightmatter.co/>

S060 | Lightelligence · 발행일 미표기

Lightelligence 공식 제품·기술 소개

<https://www.lightelligence.ai/>

S061 | Celestial AI · 2026-02-02

Celestial AI 공식 제품·기술 소개

<https://www.marvell.com/company/newsroom/marvell-completes-acquisition-of-celestial-ai.html>

S062 | Lumai · 발행일 미표기

Lumai 공식 제품·기술 소개

<https://lumai.ai/>

S063 | Q.ANT · 발행일 미표기

Q.ANT 공식 제품·기술 소개

<https://qant.com/>

출처 목록 08 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S064 | Biren Technology · 발행일 미표기

Biren Technology 공식 제품·기술 소개

<https://www.birentech.com/about/>

S065 | Moore Threads · 발행일 미표기

Moore Threads 공식 제품·기술 소개

<https://en.mthreads.com/product/S5000>

S066 | REEXEN · 발행일 미표기

REEXEN 공식 제품·기술 소개

<https://www.reexen.com/>

S067 | Cerebras · 조회 시점 FAQ

Investor FAQs

<https://investors.cerebras.ai/shareholder-services/investor-faqs>

S068 | Graphcore · 발행일 미표기

About Graphcore

<https://www.graphcore.ai/about>

S069 | Marvell · 2026-03-11

2026 Form 10-K

<https://investor.marvell.com/sec-filings/all-sec-filings/content/0001835632-26-000011/mrvl-20260131.htm>

S070 | Groq · 2025-12-24

Non-Exclusive Inference Technology Licensing Agreement

<https://groq.com/newsroom/groq-and-nvidia-enter-non-exclusive-inference-technology-licensing-agreement-to-accelerate-ai-inference-at-global-scale>

S071 | Dao et al. · 2022

FlashAttention

<https://arxiv.org/abs/2205.14135>

S072 | Xiao et al. · 2022 최초 / 2024 개정

SmoothQuant

<https://arxiv.org/abs/2211.10438>

출처 목록 09 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S073 | Lin et al. · 2023

AWQ: Activation-aware Weight Quantization

<https://arxiv.org/abs/2306.00978>

S074 | Leviathan et al. · 2022

Fast Inference from Transformers via Speculative Decoding

<https://arxiv.org/abs/2211.17192>

S075 | UCle Consortium · 조회 시점 페이지

UCle 공식 표준 안내

<https://www.uciexpress.org/>

S076 | CXL Consortium · 조회 시점 페이지

Compute Express Link 공식 안내

<https://computeexpresslink.org/>

S077 | MLCommons · 동적 페이지

MLPerf Inference: Tiny

<https://mlcommons.org/benchmarks/inference-tiny/>

S078 | Deloitte · 2026

2026 Semiconductor Industry Outlook

<https://www.deloitte.com/us/en/insights/industry/technology/technology-media-telecom-outlooks/semiconductor-industry-outlook.html>

S079 | OECD · 동적 페이지

AI compute

<https://www.oecd.org/en/topics/sub-issues/ai-compute.html>

S080 | IFR · 2025-09-25 / 2024 실적

Global Robot Demand in Factories Doubles Over 10 Years

<https://ifr.org/ifr-press-releases/global-robot-demand-in-factories-doubles-over-10-years>

S081 | IEA · 2025

Energy and AI: Executive summary

<https://www.iea.org/reports/energy-and-ai/executive-summary>

출처 목록 10 / 10

모든 URL 조회 기준: 2026-09-29. 제목은 식별을 위해 일부 축약했습니다.

S082 | BOS Semiconductors · 2025-03-12

ADAS Chiplet SoC Development Contract with European OEM

<https://www.bos-semi.com/post/bos-semiconductors-signed-development-contract-for-adas-chiplet-soc-with-an-european-oem>

S083 | Axelera AI · 2026-09-15

Europa launch and partner ecosystem

<https://axelera.ai/news/axelera-ai-launches-europa-delivers-physical-and-enterprise-ai-through-growing-partner-ecosystem-including-dell-and-supermicro>

S084 | BOS Semiconductors · 동적 문서

BOS AI Model SDK

<https://developers.bos-semi.com/>

S085 | Enfabrica · 발행일 미표기

ACF-S

<https://www.enfabrica.net/solution/acf-s>

S086 | Shanghai Stock Exchange · 2025-12-04 / 상장 2025-12-05

Moore Threads STAR Market listing notice

https://www.sse.com.cn/disclosure/announcement/listing/ipo/c/c_20251204_10800678.shtml

S087 | Lightelligence · 연혁: 2026-04-28 상장

Company Profile / Corporate Milestones

<https://www.lightelligence.ai/about-us/company-profile>

S088 | BrainChip · 2026-06-30

Commercial Availability and Production Shipments of AKD1500

<https://investor.brainchip.com/press/brainchip-announces-commercial-availability-and-production-shipments-of-akd1500-neuromorphic-processors/>

S089 | Rebellions · 2024

Rebellions and SAPEON Korea Complete Merger

<https://rebellions.ai/newsroom/rebellions-and-sapeon-korea-complete-merger-launching-koreas-first-ai-chip-unicorn/>

S090 | AiM Future · 발행일 미표기

About

https://aimfuture.ai/en/about_en/

공개 요약·소개 페이지와 실제 열람 범위를 기준으로 작성했습니다. SEMI 자료는 유료 보고서의 공개 안내만 확인했으며 비공개 본문 근거로 사용하지 않았습니다.